
Система оценки качества ответов больших языковых моделей по новостным текстам стран Восточной Азии

A System for Evaluating the Quality of Large Language Model Answers on East Asian News Texts

Багров Александр Михайлович
Факультет вычислительной математики и кибернетики
МГУ имени М. В. Ломоносова
Москва, Россия
alexbagrov04@gmail.com

Научный руководитель: Воронцов Константин Вячеславович, д. ф.-м. н.
Факультет вычислительной математики и кибернетики
МГУ имени М. В. Ломоносова
Москва, Россия

Аннотация

Промышленные вопросно-ответные системы, дополняющие большую языковую модель поиском по новостному корпусу, внедряются быстрее, чем появляются средства количественной проверки их ответов: существующие наборы вопросов либо англоязычны, либо построены из вопросов с меняющимся во времени ответом, а согласие судьи-модели с людьми и согласие самих аннотаторов в них, как правило, не сообщаются. В работе строится система оценки качества ответов больших языковых моделей на вопросы по новостным текстам стран Восточной Азии в кросс-языковой постановке: вопрос задаётся на русском языке, а источники — китайскоязычные СМИ. Объектом измерения является ответ $\hat{a} = f(q)$, где q — зафиксированный снимок корпуса, а не порождающая его модель. Система оценки включает: (1) формальную постановку с предикатом инвариантности $\text{Inv}(q)$, ограничивающим выборку статическими вопросами, ответ на которые не меняется во времени; (2) эталонную выборку $G = G^+ \sqcup G^\emptyset$ с эталонными ответами, алиасами, опорными документами, независимой разметкой тремя аннотаторами и мерой согласия Криппендорфа $\alpha \geq 0,67$; (3) семейство метрик M по эталону, цитирования, отказов и поиска, включая судью на основе языковой модели, который проходит мета-оценку отдельно на надёжность (воспроизводимость оценок) и валидность (корреляция Спирмена с человеческими оценками не ниже 0,5), после чего отбирается валидированное подсемейство M' ; (4) статистический протокол сравнения систем по композитному показателю $Q(f)$ — парный бутстреп, критерий Уилкоксона с поправкой Холма и δ Клиффа. Объект исследования — промышленная система «Chinese Media Analysis» (ИВ РАН) над корпусом СМИ КНР, Тайваня, Гонконга и Сингапура (23,9 млн фрагментов); она сравнивается с шестью открытыми моделями в режимах без поиска и с общим ретривером (13 систем).

Ключевые слова: большие языковые модели, генерация с дополнением извлечёнными данными (RAG), оценка качества ответов, эталонная выборка, статические вопросы, кросс-языковой поиск, китайскоязычные СМИ, судья на основе языковой модели, мета-оценка судьи, самопредпочтение, согласие аннотаторов.

1 Введение

Новостные тексты стран Восточной Азии — основной источник сведений для востоковедов, аналитиков и журналистов, однако объём потока и языковой барьер делают ручной мониторинг невозможным. Естественным инструментом стали системы генерации с дополнением извлечёнными данными (RAG) [1]: поисковый компонент находит фрагменты новостей, а большая языковая модель (LLM) формирует ответ на естественном языке с цитированием источников. Один из таких инструментов — промышленная система «Chinese Media Analysis», разработанная в Институте востоковедения РАН и описанная в работе [2]; она работает над корпусом китайскоязычных СМИ КНР, Тайваня, Гонконга и Сингапура объёмом 23,9 млн фрагментов и отвечает на русскоязычные вопросы.

Качество ответов таких систем до сих пор оценивалось качественно. Транскрипты сеансов показывают характерные дефекты: ложную атрибуцию (факты 2021–2025 годов со ссылкой на статью 2019 года), номера цитат, отсутствующие в списке источников, нерелевантные фрагменты с высокой косинусной близостью, непереверждённые китаизмы. Без измеримых критериев невозможно ответить на вопросы «стала ли система лучше после смены модели» и «оправдан ли поиск по корпусу по сравнению с ответом модели без поиска». Существующие средства оценки RAG [3, 4] опираются на LLM-судью без проверки его согласия с человеком на русскоязычных ответах по китайскому корпусу, хотя надёжность и валидность судьи — разные свойства, и обе требуют измерения [5, 6], а согласие судьи с людьми на русском языке заметно ниже, чем на английском [7]. Доступные наборы вопросов [8–10] либо составлены на английском и китайском языках, либо содержат зависящие от времени вопросы, из-за чего эталон устаревает [11]; вопросы, правильный ответ на которые — отказ, в них, как правило, отсутствуют, хотя именно готовность отвечать без опоры на корпус отличает системы сильнее, чем точность [12, 13].

В настоящей работе строится система оценки, объектом измерения в которой является *ответ* $\hat{a} = f(q)$ на вопрос q о новостном корпусе, а не порождающая его модель; сравнение систем — следствие применения системы оценки. Рассматриваются только статические вопросы, ответ на которые не меняется во времени (класс *never-changing* в таксономии [14]), что делает эталонную выборку долговечной. Программная система [2] является объектом исследования и не входит в результаты работы. Имеющийся в её репозитории прототип модуля оценки (LLM-судья по семи измерениям, метрики поиска), не запускавшийся и не валидированный, рассматривается как кандидатное подсемейство метрик, подлежащее валидации.

Вклад работы. Основные результаты состоят в следующем:

- формальная постановка задачи оценки качества ответов на статические вопросы по новостному корпусу: предикат инвариантности $\text{Inv}(q)$, класс гипотез $\mathcal{H}$, семейство метрик M , композитный показатель $Q(f)$ и критерий сравнения со статистической проверкой;
- эталонная выборка $G = G^+ \sqcup G^\emptyset$ статических вопросов с каноническими ответами, алиасами, опорными документами и вопросами, требующими отказа; протокол независимой разметки $R = 3$ аннотаторами с мерой согласия Криппендорфа α и адьюдикацией;
- валидированное семейство метрик M' : метрика правильности по эталону m_j^{corr} , детерминированные метрики EM, F1, BERTScore, метрики цитирования CP_{id} , CR_{id} , CP_{ent} и метрики отказов AR, $1 - \text{FAR}$; отбор метрик по коэффициенту Спирмена ρ_S с человеческими оценками;
- первое систематическое сравнение промышленной RAG-системы с открытыми моделями в режимах без поиска и с общим ретривером с парным бутстрепом, критерием Уилкоксона и поправкой Холма;

- открытые данные и код: эталонная выборка, конфигурации систем, сырые генерации, снимок списка моделей провайдера и скрипты вычисления метрик и статистики.

Структура работы. В разделе 2 рассматриваются смежные работы. Раздел 3 вводит обозначения, предположения и формальную постановку задачи. В разделе 4 описана методика построения системы оценки, в разделе 5 — план экспериментов и гипотезы. Раздел 6 посвящён рискам и ограничениям, раздел 7 содержит выводы. В приложении А приведены правила исключения вопросов и схема записи эталонной выборки.

2 Обзор литературы

Оценка систем генерации с дополнением извлечёнными данными. Фреймворк RAGAS [3] ввёл безэталонные метрики *faithfulness*, *answer relevancy* и *context relevance*, вычисляемые LLM-судьёй; ARES [4] дообучает лёгкие судьи на синтетических данных и калибрует их по небольшой размеченной выборке методом *prediction-powered inference*. Бенчмарк RGB [8] проверяет устойчивость к шуму, отказ при отсутствии информации и интеграцию нескольких источников на английских и китайских новостях; CRUD-RAG [9] строит задачи над китайскими новостями по операциям *create*, *read*, *update*, *delete*. Работы по треку TREC 2024 RAG показали, что судья надёжно оценивает поддержку утверждений цитатами [15] и что оценка по атомарным фактам эталона (*nugget*) воспроизводит ручную разметку [16], однако правильность цитирования не гарантирует, что модель действительно опиралась на источник [17], а вводящая в заблуждение выдача может сделать ответ с поиском хуже ответа без него [18]. Метрики выдачи ретривера согласуются с полнотой ответа лишь при совпадении целей поиска и генерации [19]. Эти работы задают словарь метрик, но не содержат проверки согласия судьи с человеком для русскоязычных ответов и не выделяют статические вопросы. Обзор архитектур RAG и мотивация абляции «с поиском/без поиска» восходят к [1]; на редких фактах поиск даёт наибольший выигрыш, тогда как на популярных модель без поиска конкурентоспособна [20].

Большие языковые модели как судьи. Работа [21] показала, что сильные модели согласуются с человеческими предпочтениями на уровне попарного согласия людей, но подвержены позиционному смещению, смещению к длинному ответу и ограниченной способности к проверке фактов; в чистом сценарии с высоким согласием людей даже лучшие судьи остаются заметно ниже межчеловеческого согласия [22]. В [23] установлено самопредпочтение: модель выше оценивает тексты, которые распознаёт как свои; позднее показано, что смещение распространяется на родственные модели того же семейства [24] и сохраняется даже при бинарной рубрике с объективными критериями [25], а панель судей разных семейств уменьшает его [26]. Крупнейшая мета-оценка судей [5] различает надёжность (воспроизводимость) и валидность (согласие с людьми с поправкой на случайность) и показывает, что доля совпадений превышает согласие на десятки процентных пунктов относительно κ . При оценке правильности ответа относительно эталона судья коррелирует с людьми до 0,85 против 0,22 у точного совпадения и 0,40 у F1 [27], а половина из 54 судей воспроизводит человеческое суждение о правильности ответов RAG [28]; для мета-оценки судей цитирующих систем выпущен ресурс Auto-Judge [29]. Замену человека судьёй можно обосновать статистически по небольшой размеченной подвыборке [30]. Согласие судьи, установленное на английском языке, не переносится на другие языки [31], и для русского оно заметно ниже [7]; мета-оценочные наборы для неанглийского RAG появились лишь недавно [32]. Для настоящей работы это означает, что судья не должен совпадать ни с одной из оцениваемых моделей, а его оценки нуждаются в валидации по русскоязычной человеческой разметке; согласие аннотаторов между собой измеряется по методологии [33] коэффициентом Криппендорфа α [34, 35], восходящим к π Скотта [36], с порогами интерпретации [37–39]; для свободных ответов согласие измеряется попарной F-мерой, которая при большом числе отрицательных случаев сходится к κ [40]. Часть расхождений аннотаторов — законная вариативность, а не шум [41], что и мотивирует адьюдикацию вместо отбраковки.

Временная динамика вопросов и построение выборки. Таксономия FreshQA [14] делит вопросы на *never-changing*, *slow-changing*, *fast-changing* и вопросы с ложной предпосылкой; эталонная выборка настоящей работы ограничена первым классом и вторым при явной дате-якоре. Обзор темпорального QA [42] выделяет темпоральность вопроса как самостоятельное измерение, а набор RecensyQA [11] показывает, что стационарность ответа — размечаемое свойство вопроса. Китайские наборы CDQA [43] и ChronoQA [10] (5176 вопросов по 300 тыс. китайских новостей) намеренно строятся из времязависимых вопросов, а DRAGON [44]

регулярно пересобирает набор по свежим российским новостям, то есть эти работы решают противоположную задачу; вымышленные новостные события NeoQA [45] исключают утечку знаний из предобучения, но неприменимы к оценке реальной системы над реальным корпусом. Отказ на неотвечаемых вопросах остаётся нерешённой задачей [13]: системы с поиском отказываются от вопросов, на которые могли ответить, и отвечают там, где корпус не содержит ответа [46, 47], поэтому вопросы с правильным ответом-отказом и вопросы, ответ на которые заведомо отсутствует в базе [12], включаются в выборку. Протокол разметки с несколькими независимыми аннотаторами и отдельными метками отвечаемости и ответа заимствован из Natural Questions [48].

Китайско- и русскоязычные ресурсы и метрики генерации. Метрики точного совпадения и токенового F1 введены в SQuAD [49]. BERTScore [50] измеряет семантическую близость с помощью контекстных представлений и устойчив к перефразированию и транслитерации имён; сама передача китайских имён средствами русского языка допускает несколько равноправных вариантов [51], что требует алиасов в эталоне. Метрики точности и полноты цитирования предложены в ALCE [52]: утверждение считается подтверждённым, если хотя бы один процитированный фрагмент влечёт его по модели NLI; при этом в многоязычной выдаче модели предпочитают цитировать источники на языке запроса даже в ущерб релевантности [53]. Постановку «вопрос на одном языке — свидетельства на другом» формализует XOR QA [54]; для кросс-языкового RAG показано, что смена языка выдачи снижает качество генерации [55]. Русскоязычные ресурсы оценки — REPA [7], POLLUX с открытыми судьями [56] и RusHallu-RAG [57] — покрывают генерацию и детекцию галлюцинаций на русском, но не вопросно-ответные системы над иноязычным новостным корпусом. В обзоре [2] сопоставлены функциональные возможности цифровых инструментов анализа СМИ Северо-Восточной Азии и описана архитектура исследуемой системы, однако количественная оценка ответов в нём отсутствует — этот пробел и закрывает настоящая работа.

Основы оценки поиска и статистика сравнения систем. Парадигма тестовой коллекции — фиксированный корпус, запросы и эталонные оценки релевантности — восходит к Крэнфилдским экспериментам [58]; уже тогда было показано, что расхождения ассессоров почти не меняют относительный порядок систем [59, 60], а первый QA-трек TREC ввёл MRR и ручную проверку ответов [61]. Метрика nDCG [62] учитывает позицию опорного документа в выдаче. Парные критерии по запросам корректнее сравнения средних [63]: используются критерий знаковых рангов Уилкоксона [64], парный бутстреп по примерам [65, 66], поправка Холма на множественные сравнения [67] и порядковая мера размера эффекта δ Клиффа [68]; корреляция Спирмена [69] служит критерием валидности метрик. Выбор критерия по типу метрики следует протоколу [70]; оценка LLM как эксперимент над выборкой вопросов требует парных сравнений и планирования размера [71], а при менее чем нескольких сотнях вопросов интервалы по центральной предельной теореме занижают неопределённость [72]. Шум несовершенного судьи можно учесть при проверке гипотез, откалибровав его по человеческой подвыборке [73].

3 Основные понятия и обозначения

3.1 Общие обозначения

В этом разделе вводятся обозначения, используемые далее без изменений (таблица 1).

Определение 1 (статический вопрос). Пусть $a^*(q, t) \in \mathcal{A}$ — истинный ответ на вопрос q при состоянии мира в момент t . Вопрос q называется статическим (инвариантным во времени) относительно t_0 , если

$$\text{Inv}(q) \iff \exists a^*(q) \in \mathcal{A}^+ : \forall t \geq t_0 \quad a^*(q, t) = a^*(q). \quad (1)$$

Определение 2 (ответ большой языковой модели). Ответом большой языковой модели на вопрос q называется выход $f(q) = (\hat{a}, \hat{S})$ гипотезы $f \in \mathcal{H}$, завершающим шагом которой является генерация текста языковой моделью — с поиском по корпусу или без него. Метрика $m_k(\hat{a}, \hat{S}; G_i)$ определена на ответах; модель или система входит в неё только через f .

Определение 3 (эталонная выборка). Эталонной выборкой называется $G = G^+ \sqcup G^\emptyset$, где $G^+ = \{(q_i, A_i^*, S_i^*, \mu_i)\}_{i=1}^{n+}$ — статические вопросы с непустым множеством эталонных ответов A_i^* (канонический ответ и алиасы, включая транслитерации), опорными документами $|S_i^*| \geq 1$ и метаданными μ_i (тип, категория, источник, дата-якорь, голоса аннотаторов,

Таблица 1: Основные обозначения

Символ	Смысл
t_0	момент фиксации корпуса
$D = \{d_j\}_{j=1}^N$	снимок корпуса; $d_j = (\iota_j, u_j, \tau_j, s_j, x_j^{zh}, x_j^{ru})$ — стабильный идентификатор, URL, дата публикации $\tau_j \leq t_0$, источник, текст оригинала, машинный перевод
$\mathcal{I}$	множество идентификаторов ι_j ; фрагмент любого ретривера отображается в ι_j
$\mathcal{Q}$	пространство вопросов на русском языке
$\mathcal{A} = \mathcal{A}^+ \sqcup \{\emptyset\}$	пространство ответов; $\emptyset$ — отказ «Я не знаю.»
$2^{\mathcal{I}}$	пространство цитирований (множеств идентификаторов)
$a^*(q, t), \text{Inv}(q)$	истинный ответ при состоянии мира в момент t ; предикат инвариантности ответа во времени
$G = G^+ \sqcup G^\emptyset$	эталонная выборка: отвечаемые и требующие отказа вопросы; $ G^+ = n_+$, $ G^\emptyset = n_\emptyset$, $n = n_+ + n_\emptyset$
$G_i = (q_i, A_i^*, S_i^*, \mu_i)$	запись G^+ : вопрос, множество эталонных ответов (канонический и алиасы), опорные документы $S_i^* \subset \mathcal{I}$, метаданные
$\mathcal{H}, \mathcal{H}_{\text{eval}}$	класс гипотез $\{f : \mathcal{Q} \rightarrow \mathcal{A} \times 2^{\mathcal{I}}\}$ и оцениваемое подмножество
$\mathcal{L}$	множество открытых моделей провайдера
$f_{\text{prod}}, f_0^{(m)}, f_\rho^{(m)}$	промышленная система; модель m без поиска; модель m с ретривером
$M = \{m_k\}, M'$	ρ_{prod} семейство метрик и валидированное подсемейство
$h_{i,f}^{(r)}, \bar{h}_{i,f}$	оценка r -го аннотатора ответа $f(q_i)$ и её среднее по r
$G_h, \mathcal{H}_h$	подвыборка для человеческой валидации, $ G_h = n_h$; оцениваемые людьми системы
$Q(f), f^*$	композиционный показатель и лучшая система
ρ_S, α	коэффициент Спирмена; коэффициент согласия Криппендорфа (не путать с уровнем значимости, для которого используется $\alpha = 0,05$ явно)

сложность, разбиение), а $G^\emptyset$ — вопросы, инвариантные по форме, но не подтверждаемые корпусом, для которых правильным ответом является отказ $\emptyset$; $n_\emptyset \approx 0,1n$.

3.2 Предположения

Предположение 1 (операционализация инвариантности). Предикат (1) непроверяем непосредственно, поэтому вопрос признаётся статическим, если (а) ответ полностью определяется корпусом, $a^*(q) = g(q, D)$; (б) существует непустое $S_q^* \subset \mathcal{I}$, документы которого влекут $a^*(q)$; (в) вопрос содержит явную дату-якорь. Оценка по меткам R аннотаторов $z_r(q) \in \{0, 1\}$:

$$\widehat{\text{Inv}}(q) = \mathbb{I} \left[\sum_{r=1}^R z_r(q) = R \right]. \quad (2)$$

Предположение 2 (правила исключения). До разметки инвариантности к вопросу применяются правила E_1 – E_5 (приложение А.1): E_1 — прогнозы и гипотетика; E_2 — маркеры «сейчас», «на данный момент», «последний», «текущая ситуация»; E_3 — величины без даты-якоря (цены, курсы, индексы, действующие должностные лица); E_4 — ответ зависит от момента запроса или политической оценки; E_5 — ложная предпосылка. В терминах [14] допускаются вопросы *never-changing*, вопросы *slow-changing* — только с датой-якорем; *fast-changing* и *false-premise* исключаются.

Предположение 3 (независимость судьи). Модель-судья, реализующая метрики m_J^{corr} и $m_J^{(d)}$, не принадлежит множеству $\mathcal{L} \cup \{g_{\theta_{\text{prod}}}\}$; в противном случае используется ансамбль двух судей. Самопредпочтение судьи проверяется отдельно (гипотеза H_5).

Предположение 4 (воспроизводимость прогонов). Генерация выполняется при *temperature* 0 и фиксированном *seed*; поле *model* каждого ответа и снимок списка моделей провайдера (*/v1/models*) сохраняются; при неизвестной модели прогон прерывается (*fail-fast*), что исключает тихую подмену модели провайдером.

3.3 Постановка задачи

Дано.

1. Момент фиксации t_0 и снимок корпуса $D = \{d_j\}_{j=1}^N$ с идентификаторами $\mathcal{I}$.
2. Пространства $\mathcal{Q}, \mathcal{A} = \mathcal{A}^+ \sqcup \{\emptyset\}$, $2^{\mathcal{I}}$ и предикат $\text{Inv}(q)$ (1) с оценкой (2).
3. Класс гипотез и оцениваемое подмножество

$$\mathcal{H} = \{f : \mathcal{Q} \rightarrow \mathcal{A} \times 2^{\mathcal{I}}\}, \quad f(q) = (\hat{a}, \hat{S}), \quad (3)$$

$$\mathcal{H}_{\text{eval}} = \{f_{\text{prod}}\} \cup \{f_0^{(m)}\}_{m \in \mathcal{L}} \cup \{f_{\rho}^{(m)}\}_{m \in \mathcal{L}}, \quad (4)$$

где $f_{\text{prod}} = g_{\theta_{\text{prod}}} \circ \rho_{\text{prod}}$ — промышленная система (Qdrant + SearchAPI + генератор), $f_0^{(m)} = (g_m(q), \emptyset)$ — открытая модель без поиска, $f_{\rho}^{(m)} = g_m \circ \rho_{\text{prod}}$ — та же выдача ретривера с другой моделью (контексты кэшируются; абляция «модель против ретривера»).

4. Семейство метрик $M = \{m_k\}$, $m_k : \mathcal{A} \times 2^{\mathcal{I}} \times G_i \rightarrow [0, 1] \cup \{\text{NA}\}$, «больше — лучше»:
 - по эталону (на G^+): $\text{EM} = \max_{a \in A_i^+} \mathbb{I}[\text{norm}(\hat{a}) = \text{norm}(a)]$; токентный F1 после лемматизации, максимум по алиасам; BERTScore-F1 с мультязычным энкодером; m_J^{corr} — LLM-судья «правильность относительно A_i^* », шкала 0–5, делённая на 5; $m_J^{(d)}$, $d \in \{\text{faithfulness, answer_relevancy, completeness, citation_accuracy, temporal_correctness, allegory_idiom_quality, hallucination_abstention}\}$ — существующая рубрика как кандидатное подсемейство;
 - цитирование: $\text{CP}_{\text{id}} = |\hat{S} \cap S_i^*|/|\hat{S}|$ (NA при $\hat{S} = \emptyset$), $\text{CR}_{\text{id}} = |\hat{S} \cap S_i^*|/|S_i^*|$ (для систем без поиска равна 0), $\text{CP}_{\text{ent}} = \frac{1}{|\hat{S}|} \sum_{\iota \in \hat{S}} \mathbb{I}[x_{\iota} \models \hat{a}]$ по модели NLI или судье [52];
 - отказы: $\text{AR} = \frac{1}{n_{\emptyset}} \sum_{G^{\emptyset}} \mathbb{I}[\hat{a} = \emptyset]$ и $1 - \text{FAR}$, где $\text{FAR} = \frac{1}{n_+} \sum_{G^+} \mathbb{I}[\hat{a} = \emptyset]$;
 - поиск (компонент ρ): $\text{Hit}@k$, $\text{Recall}@k$, MRR , $\text{nDCG}@k$ относительно S_i^* .
5. Человеческие оценки $h_{i,f}^{(r)} \in \{0, \dots, 5\}$ (правильность, обоснованность) на $G_h \subset G^+$, $|G_h| = n_h$, для систем $\mathcal{H}_h \subset \mathcal{H}_{\text{eval}}$; $\bar{h}_{i,f}$ — среднее по r .

Найти.

1. Эталонную выборку G , удовлетворяющую ограничениям ниже.
2. Валидированное подсемейство метрик

$$M' = \{m_k \in M : \rho_S(m_k, \bar{h}) \geq \rho_{\min} \text{ на } G_h \times \mathcal{H}_h\}, \quad \rho_{\min} = 0,5, \quad (5)$$

где ρ_S вычисляется с 95 %-м бутстреп-интервалом, а потолком служит среднее попарное согласие аннотаторов. Детерминированные метрики без человеческого аналога ($\text{Recall}@k$ и т. п.) включаются в M' непосредственно.

3. Для $f \in \mathcal{H}_{\text{eval}}$ и $m_k \in M'$ — средние по вопросам, композитный показатель и лучшую систему:

$$\bar{m}_k(f) = \frac{1}{|I_k(f)|} \sum_{i \in I_k(f)} m_k(f(q_i); G_i), \quad I_k(f) = \{i : m_k \neq \text{NA}\}, \quad (6)$$

$$Q(f) = \sum_k w_k \bar{m}_k(f), \quad w_k \geq 0, \quad \sum_k w_k = 1, \quad (7)$$

$$f^* = \arg \max_{f \in \mathcal{H}_{\text{eval}}} Q(f) \quad (8)$$

с проверкой значимости парных различий; по умолчанию веса w_k равные.

Критерий качества и статистика. Первичная метрика фиксируется до эксперимента: m_J^{corr} , если она проходит валидацию (5), иначе F1; остальные метрики вторичные. Для пары систем (f, f') на общих вопросах вычисляются разности $\delta_i = m_k(f(q_i)) - m_k(f'(q_i))$; для δ строится перцентильный 95 %-й интервал парным бутстрепом по вопросам ($B = 10^4$); применяется

критерий Уилкоксона знаковых рангов с поправкой Холма при уровне значимости 0,05 по всем $f' \neq f_{\text{prod}}$; размер эффекта — δ Клиффа. Разбивка по стратам (категория, источник, тип вопроса, известность события) приводится описательно. Для судьи фиксируются temperature 0 и отчёт о собственной воспроизводимости.

Ограничения. Снимок D_{t_0} зафиксирован (дата, N , хеш списка $\mathcal{I}$); $S_i^* \subset \mathcal{I}$ и присутствует в индексе, поэтому покрытие корпуса равно 1 по построению; $n \geq 150$ (цель 200–300); не менее трёх доменов, двух регионов и охват не менее 12 месяцев; разбиение dev (30 вопросов) / test. Публикуются идентификаторы, URL, даты и короткие фрагменты-свидетельства, но не полные тексты документов.

4 Метод

Система оценки строится за девять этапов; каждый этап описан так, чтобы его мог воспроизвести другой исследователь по опубликованным конфигурациям.

1. **Отбор документов.** Стратифицированная выборка из пересечения хранилища веб-страниц и индекса Qdrant по стратам «домен $\times$ месяц $\times$ категория» с переизбытком $\times 2$; фиксируются t_0 , N и хеш списка $\mathcal{I}$.
2. **Черновики вопросов.** Модель $g_{\text{draft}} \notin \mathcal{L}$ порождает по документу кортеж $(q, a, S, \text{evidence}, \text{тип}, \text{дата})$. Существующие 388 вопросов [2] после перекидки ключей $\text{warc_id} \rightarrow \text{webpage_id}$ служат исходным пулом (seed pool), а не эталоном: у них нет эталонных ответов и признака статичности.
3. **Независимая разметка.** $R = 3$ аннотатора (не менее одного читающего по-китайски) независимо размечают инвариантность по правилам E_1 – E_5 , отвечаемость, тип вопроса и правят ответ.
4. **Согласие.** По меткам инвариантности, отвечаемости и типа вычисляется коэффициент Криппендорфа α ($\alpha \geq 0,67$ допустимо, $\alpha \geq 0,8$ надёжно); по ответам — попарный токенистый F1 с порогом 0,8.
5. **Сборка G .** Вопрос включается при единогласии (2), при расхождении — после адьюдикации четвёртым экспертом. Пилот на 30 вопросах $\rightarrow$ правка инструкции $\rightarrow$ полный прогон $\rightarrow$ заморозка версии v1.0 (sha256, журнал изменений).
6. **Метрики M .** Реализуются метрики по эталону, цитирования, отказов и поиска из раздела 3.3; существующая семимерная рубрика подключается как кандидатное подсемейство $\{m_f^{(d)}\}$.
7. **Валидация M' .** На G_h ($n_h = 100$) собираются оценки $h_{i,f}^{(r)}$ для $\mathcal{H}_h$; по (5) отбираются метрики с $\rho_S \geq 0,5$; отдельно проверяется самопредпочтение судьи.
8. **Прогоны.** Для всех $f \in \mathcal{H}_{\text{eval}}$ при temperature 0 и фиксированном seed сохраняются сырые генерации, цитирования, поле model, git sha и снимок /v1/models (предположение 4).
9. **Статистика.** Вычисляются $\bar{m}_k(f)$, $Q(f)$ (7), парные разности с бутстреп-интервалами, критерий Уилкоксона с поправкой Холма и δ Клиффа; результаты сводятся в таблицу вида таблицы 2.

5 Эксперименты

Для проверки гипотез запланирована эмпирическая часть, параметры которой фиксируются до начала прогонов.

Оцениваемые системы. $\mathcal{L} = \{\text{DeepSeek-R1-Distill-Qwen-32B}, \text{Qwen3.6-27B}, \text{Qwen3.8-27B}, \text{GigaChat-20B-A3B}, \text{GLM-4.1V-9B-Thinking}, \text{Qwen-AgentWorld-35B-A3B}\}$ — шесть открытых моделей провайдера ИВ РАН (исключены специализированные Hy-MT2, Laguna-XS и Qwen3-Coder). В двух режимах ($f_0^{(m)}$ и $f_\rho^{(m)}$) вместе с f_{prod} это даёт $|\mathcal{H}_{\text{eval}}| = 13$ систем.

Размеры. Эталонная выборка $n = 200$ –300 (не менее 150), $n_\emptyset \approx 0,1n$, $R = 3$ аннотатора, подвыборка человеческой валидации $n_h = 100$, разбиение dev/test = 30/($n - 30$).

Бюджет вычислений. Разметка: $3 \times 250 \times 5$ мин ≈ 21 ч на аннотатора. Генерации: $13 \times 250 \approx 4750$ вызовов (около 40 ч последовательно). Судья: около 25 ч. При сокращённом варианте (защита зимой): $n = 150$, 8 систем, $n_h = 60$.

Гипотезы.

- H_1 (основная): $Q(f_{\text{prod}}) > Q(f_0^{(m)})$ для всех $m \in \mathcal{L}$.
- H_2 (сильная): $Q(f_{\text{prod}}) > Q(f_p^{(m)})$ для всех $m \in \mathcal{L}$; при опровержении вклад ретривера и модели разделяется явно.
- H_3 : $Q(f_p^{(m)}) > Q(f_0^{(m)})$ — поиск по корпусу повышает качество ответов.
- H_4 : $\rho_S(m_J^{\text{corr}}, \bar{h}) \geq 0,5$ и $\alpha_{\text{human}} \geq 0,67$ — метрика правильности по эталону и разметка надёжны.
- H_5 : самопредпочтение судьи статистически незначимо.

План работ. Сентябрь–октябрь 2026 — постановка, инструкция разметки, пилот на 30 вопросах, обзор литературы; ноябрь–декабрь — разметка 250 вопросов и заморозка v1.0; январь 2027 — прогоны; февраль — валидация метрик и статистика; март–апрель — текст и слайды; защита — июнь 2027.

Таблица 2: Заготовка главной таблицы результатов. В ячейках — $\bar{m}_k(f)$ с 95 %-м бутстреп-интервалом; звёздочкой отмечаются различия с f_{prod} , значимые после поправки Холма ($p_{\text{Holm}} < 0,05$). Значения будут заполнены после прогонов.

Система	Режим	m_J^{corr}	F1	CP _{id}	AR	1 – FAR	$Q(f)$ (ранг)
f_{prod}	Qdrant + SearchAPI	...	...	...	...	...	...
$f_0^{(m_1)}$	без поиска	...	...	NA	...	...	...
$f_0^{(m_2)}$	без поиска	...	...	NA	...	...	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$f_p^{(m_1)}$	ρ_{prod}	...	...	...	...	...	...
$f_p^{(m_2)}$	ρ_{prod}	...	...	...	...	...	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

6 Обсуждение

Самопредпочтение судьи. Фактический генератор промышленной системы — DeepSeek-R1-Distill-Qwen-32B, входящая и в $\mathcal{L}$. Если судья окажется той же или родственной моделью, оценки m_J^{corr} будут смещены в пользу её ответов [23, 24]. Меры: предположение 3, гипотеза H_5 , панель судей разных семейств [26] и опора на детерминированные метрики EM, F1, CP_{id} как контроль.

Подмена модели провайдером. Локальный провайдер (llama-swap) может тихо заменить неизвестную модель на модель по умолчанию, что уже наблюдалось для конфигурации по умолчанию. Мера: fail-fast, запись поля model каждого ответа и снимка списка моделей (предположение 4).

Утечка знаний в предобучение. События 2022–2023 годов могли попасть в обучающие данные открытых моделей, и высокий результат $f_0^{(m)}$ может отражать память модели, а не рассуждение по корпусу; известно, что на популярных сущностях параметрическая память конкурентоспособна с поиском [20]. Мера: страта «известность события» в метаданных μ_i и описательная разбивка результатов по ней; вопросы $G^\emptyset$ дополнительно проверяют склонность к уверенному ответу без опоры [12].

Транслитерация имён и терминов. Русская передача китайских имён и названий неоднозначна [51], что ломает EM и токанный F1. Мера: алиасы в A_i^* и мягкие метрики (BERTScore, m_J^{corr}); согласие судьи с человеком на таких вопросах проверяется отдельно.

Область применимости. В названии работы указаны страны Восточной Азии, тогда как корпус исследуемой системы на текущем этапе китайскоязычный. Методика не зависит от языка корпуса, а расширение выборки на японские и корейские источники требует лишь повторения этапов 1–5 раздела 4 с аннотаторами, владеющими соответствующими языками. Метрики поиска воспроизводимы только при доступе к индексу ИВ РАН; все прочие метрики воспроизводимы по опубликованным данным.

7 Заключение

В работе поставлена задача оценки качества ответов больших языковых моделей на статические вопросы по новостному корпусу стран Восточной Азии: введён предикат инвариантности $\text{Inv}(q)$, определены эталонная выборка $G = G^+ \sqcup G^\emptyset$, класс гипотез $\mathcal{H}_{\text{eval}}$, семейство метрик M и композитный показатель $Q(f)$ с процедурой статистического сравнения. Предложена девятиэтапная методика построения системы оценки, включающая независимую разметку тремя аннотаторами, измерение согласия и валидацию метрик по человеческим оценкам. Сформулированы гипотезы H_1 – H_5 и план экспериментов над промышленной системой [2] и шестью открытыми моделями в двух режимах. Результатом работы станут опубликованная эталонная выборка, валидированное подсемейство метрик M' и главная таблица результатов с интервалами и поправкой на множественные сравнения.

Список литературы

- [1] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020. URL <https://arxiv.org/abs/2005.11401>.
- [2] А. М. Багров, Н. В. Иванченко, А. В. Костыркин, Р. Ф. Кудакеев, А. А. Маркин, and А. Ч. Мокрецкий. К вопросу о цифровых инструментах анализа СМИ стран Северо-Восточной Азии. *Проблемы Дальнего Востока*, (1):147–156, 2026. doi: 10.7868/S2712909826010109.
- [3] Shahul Es et al. Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023. URL <https://arxiv.org/abs/2309.15217>. EACL 2024, System Demonstrations.
- [4] Jon Saad-Falcon et al. ARES: An automated evaluation framework for retrieval-augmented generation systems. *arXiv preprint arXiv:2311.09476*, 2023. URL <https://arxiv.org/abs/2311.09476>. NAACL 2024.
- [5] Justin D. Norman, Michael U. Rivera, and D. Alex Hughes. Reliability without validity: A systematic, Large-Scale evaluation of LLM-as-a-Judge models across agreement, consistency, and bias. *arXiv preprint arXiv:2606.19544*, 2026. URL <https://arxiv.org/abs/2606.19544>.
- [6] Yusuke Yamauchi et al. An empirical study of LLM-as-a-judge: How design choices impact evaluation reliability. *arXiv preprint arXiv:2506.13639*, 2025. URL <https://arxiv.org/abs/2506.13639>.
- [7] Alexander Pugachev, Alena Fenogenova, Vladislav Mikhailov, and Ekaterina Artemova. REPA: Russian error types annotation for evaluating text generation and judgment capabilities. *arXiv preprint arXiv:2503.13102*, 2025. URL <https://arxiv.org/abs/2503.13102>.
- [8] Jiawei Chen et al. Benchmarking large language models in retrieval-augmented generation. *arXiv preprint arXiv:2309.01431*, 2023. URL <https://arxiv.org/abs/2309.01431>. AAAI 2024.
- [9] Yuanjie Lyu et al. CRUD-RAG: A comprehensive Chinese benchmark for retrieval-augmented generation of large language models. *arXiv preprint arXiv:2401.17043*, 2024. URL <https://arxiv.org/abs/2401.17043>.
- [10] Ziyang Chen et al. A question answering dataset for temporal-sensitive retrieval-augmented generation. *arXiv preprint arXiv:2508.12282*, 2025. URL <https://arxiv.org/abs/2508.12282>.

- [11] Bhawna Piryani, Zehra Mert, and Adam Jatowt. How often do answers change? estimating recency requirements in question answering. *arXiv preprint arXiv:2603.16544*, 2026. URL <https://arxiv.org/abs/2603.16544>.
- [12] Alden Do Rosario, Hussein Younes, and Felipe Pires. Why RAGs hallucinate: Penalty-Aware evaluation of Retrieval-Augmented generation systems with Knowledge-Gap canaries. *arXiv preprint arXiv:2608.26385*, 2026. URL <https://arxiv.org/abs/2608.26385>.
- [13] Polina Kirichenko, Mark Ibrahim, Kamalika Chaudhuri, and Samuel J. Bell. AbstentionBench: Reasoning LLMs fail on unanswerable questions. *arXiv preprint arXiv:2506.09038*, 2025. URL <https://arxiv.org/abs/2506.09038>.
- [14] Tu Vu et al. FreshLLMs: Refreshing large language models with search engine augmentation. *arXiv preprint arXiv:2310.03214*, 2023. URL <https://arxiv.org/abs/2310.03214>.
- [15] Nandan Thakur, Ronak Pradeep, Shivani Upadhyay, Daniel Campos, Nick Craswell, Ian Soboroff, Hoa Trang Dang, and Jimmy Lin. Assessing support for the TREC 2024 RAG track: A large-scale comparative study of LLM and human evaluations. In *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2759–2763, 2025. doi: 10.1145/3726302.3730165.
- [16] Ronak Pradeep, Nandan Thakur, Shivani Upadhyay, Daniel Campos, Nick Craswell, and Jimmy Lin. The great nugget recall: Automating fact extraction and RAG evaluation with large language models. *arXiv preprint arXiv:2504.15068*, 2025. URL <https://arxiv.org/abs/2504.15068>.
- [17] Jonas Wallat, Maria Heuss, Maarten de Rijke, and Avishek Anand. Correctness is not faithfulness in retrieval augmented generation attributions. In *Proceedings of the 2025 International ACM SIGIR Conference on Innovative Concepts and Theories in Information Retrieval (ICTIR)*, pages 22–32, 2025. doi: 10.1145/3731120.3744592.
- [18] Linda Zeng, Rithwik Gupta, Divij Motwani, Yi Zhang, and Diji Yang. Worse than zero-shot? a Fact-Checking dataset for evaluating the robustness of RAG against misleading retrievals. *arXiv preprint arXiv:2502.16101*, 2025. URL <https://arxiv.org/abs/2502.16101>.
- [19] Saron Samuel, Alexander Martin, Eugene Yang, Andrew Yates, Dawn Lawrie, Ian Soboroff, Laura Dietz, and Benjamin Van Durme. Beyond relevance: On the relationship between retrieval and RAG information coverage. *arXiv preprint arXiv:2603.08819*, 2026. URL <https://arxiv.org/abs/2603.08819>.
- [20] Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. When not to trust language models: Investigating effectiveness of parametric and Non-Parametric memories. *arXiv preprint arXiv:2212.10511*, 2022. URL <https://arxiv.org/abs/2212.10511>.
- [21] Lianmin Zheng et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *arXiv preprint arXiv:2306.05685*, 2023. URL <https://arxiv.org/abs/2306.05685>. NeurIPS 2023, Datasets and Benchmarks Track.
- [22] Aman Singh Thakur, Kartik Choudhary, Venkat Srinik Ramayapally, Sankaran Vaidyanathan, and Dieuwke Hupkes. Judging the judges: Evaluating alignment and vulnerabilities in LLMs-as-Judges. *arXiv preprint arXiv:2406.12624*, 2024. URL <https://arxiv.org/abs/2406.12624>. GEM² Workshop, ACL 2025.
- [23] Arjun Panickssery et al. LLM evaluators recognize and favor their own generations. *arXiv preprint arXiv:2404.13076*, 2024. URL <https://arxiv.org/abs/2404.13076>.
- [24] Dawei Li, Renliang Sun, Yue Huang, Ming Zhong, Bohan Jiang, Jiawei Han, Xiangliang Zhang, Wei Wang, and Huan Liu. Preference leakage: A contamination problem in LLM-as-a-judge. *arXiv preprint arXiv:2502.01534*, 2025. URL <https://arxiv.org/abs/2502.01534>.
- [25] José Pombal, Ricardo Rei, and André F. T. Martins. Self-Preference bias in Rubric-Based evaluation of large language models. *arXiv preprint arXiv:2604.06996*, 2026. URL <https://arxiv.org/abs/2604.06996>.

- [26] Pat Verga, Sebastian Hofstätter, Sophia Althammer, Yixuan Su, Aleksandra Piktus, Arkady Arkhangorodsky, Minjie Xu, Naomi White, and Patrick Lewis. Replacing judges with juries: Evaluating LLM generations with a panel of diverse models. *arXiv preprint arXiv:2404.18796*, 2024. URL <https://arxiv.org/abs/2404.18796>.
- [27] Xanh Ho, Jiahao Huang, Florian Boudin, and Akiko Aizawa. Reassessing extractive QA datasets at scale: LLM-as-a-Judge and In-Depth analyses. *arXiv preprint arXiv:2504.11972*, 2025. URL <https://arxiv.org/abs/2504.11972>.
- [28] Steve Han, Gilberto Titericz Junior, Tom Balough, and Wenfei Zhou. Judge’s verdict: A comprehensive analysis of LLM judge capability through human agreement. *arXiv preprint arXiv:2510.09738*, 2025. URL <https://arxiv.org/abs/2510.09738>.
- [29] Naghmeh Farzi, Tim Hagen, Eugene Yang, Maik Fröbe, Ronak Pradeep, Hossein A. Rahmani, Xi Wang, Oleg Zendel, Martin Potthast, and Laura Dietz. Auto-Judge: A cross-task benchmark for comparing LLM judges for citation-grounded RAG systems. In *Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 3159–3166, 2026. doi: 10.1145/3805712.3808601.
- [30] Nitay Calderon, Roi Reichart, and Rotem Dror. The alternative annotator test for LLM-as-a-Judge: How to statistically justify replacing human annotators with LLMs. *arXiv preprint arXiv:2501.10970*, 2025. URL <https://arxiv.org/abs/2501.10970>.
- [31] Xiyan Fu and Wei Liu. How reliable is multilingual LLM-as-a-Judge? *arXiv preprint arXiv:2505.12201*, 2025. URL <https://arxiv.org/abs/2505.12201>.
- [32] María Andrea Cruz Blandón, Jayasimha Talur, Bruno Charron, Dong Liu, Saab Mansour, and Marcello Federico. MEMERAG: A multilingual End-to-End Meta-Evaluation benchmark for retrieval augmented generation. *arXiv preprint arXiv:2502.17163*, 2025. URL <https://arxiv.org/abs/2502.17163>.
- [33] Ron Artstein and Massimo Poesio. Survey article: Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4):555–596, 2008. doi: 10.1162/coli.07-034-R2. URL <https://aclanthology.org/J08-4004/>.
- [34] Klaus Krippendorff. Estimating the reliability, systematic error and random error of interval data. *Educational and Psychological Measurement*, 30(1):61–70, 1970. doi: 10.1177/001316447003000105.
- [35] Klaus Krippendorff. Computing Krippendorff’s alpha-reliability. Technical report, Annenberg School for Communication, University of Pennsylvania, 2011. URL <https://www.asc.upenn.edu/sites/default/files/2021-03/Computing%20Krippendorff's%20Alpha-Reliability.pdf>.
- [36] William A. Scott. Reliability of content analysis: The case of nominal scale coding. *Public Opinion Quarterly*, 19(3):321–325, 1955. doi: 10.1086/266577.
- [37] J. Richard Landis and Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977. doi: 10.2307/2529310.
- [38] Jean Carletta. Assessing agreement on classification tasks: The kappa statistic. *Computational Linguistics*, 22(2):249–254, 1996. URL <https://aclanthology.org/J96-2004/>.
- [39] Klaus Krippendorff. Reliability in content analysis: Some common misconceptions and recommendations. *Human Communication Research*, 30(3):411–433, 2004. doi: 10.1093/hcr/30.3.411.
- [40] George Hripcsak and Adam S. Rothschild. Agreement, the F-measure, and reliability in information retrieval. *Journal of the American Medical Informatics Association*, 12(3):296–298, 2005. doi: 10.1197/jamia.M1733.
- [41] Barbara Plank. The ‘problem’ of human label variation: On ground truth in data, modeling and evaluation. *arXiv preprint arXiv:2211.02570*, 2022. URL <https://arxiv.org/abs/2211.02570>.

- [42] Bhawna Piryani, Abdelrahman Abdallah, Jamshid Mozafari, Avishek Anand, and Adam Jatowt. It’s high time: A survey of temporal question answering. *arXiv preprint arXiv:2505.20243*, 2025. URL <https://arxiv.org/abs/2505.20243>. ACL 2026.
- [43] Zhikun Xu et al. Let LLMs take on the latest challenges! A Chinese dynamic question answering benchmark. *arXiv preprint arXiv:2402.19248*, 2024. URL <https://arxiv.org/abs/2402.19248>. COLING 2025.
- [44] Fedor Chernogorskii, Sergei Averkiev, Liliya Kudraleeva, Zaven Martirosian, Maria Tikhonova, Valentin Malykh, and Alena Fenogenova. DRAGON: Designing RAG on periodically updated corpus. *arXiv preprint arXiv:2507.05713*, 2025. URL <https://arxiv.org/abs/2507.05713>.
- [45] Max Glockner, Xiang Jiang, Leonardo F. R. Ribeiro, Iryna Gurevych, and Markus Dreyer. NeoQA: Evidence-based question answering with generated news events. *arXiv preprint arXiv:2505.05949*, 2025. URL <https://arxiv.org/abs/2505.05949>.
- [46] Youchao Zhou, Heyan Huang, Yicheng Liu, Rui Dai, Xinglin Wang, Xingchen Zhang, Shumin Shi, and Yang Deng. Do retrieval augmented language models know when they don’t know? *arXiv preprint arXiv:2509.01476*, 2025. URL <https://arxiv.org/abs/2509.01476>.
- [47] Gabrielle Kaili-May Liu, Bryan Li, Arman Cohan, William Gantt Walden, and Eugene Yang. Investigating Retrieval-Augmented generation systems on unanswerable, uncheatable, realistic, multi-hop queries. *arXiv preprint arXiv:2510.11956*, 2025. URL <https://arxiv.org/abs/2510.11956>.
- [48] Tom Kwiatkowski et al. Natural questions: A benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7:453–466, 2019. doi: 10.1162/tacl_a_00276. URL <https://aclanthology.org/Q19-1026/>.
- [49] Pranav Rajpurkar et al. SQuAD: 100,000+ questions for machine comprehension of text. *arXiv preprint arXiv:1606.05250*, 2016. URL <https://arxiv.org/abs/1606.05250>. EMNLP 2016.
- [50] Tianyi Zhang et al. BERTScore: Evaluating text generation with BERT. *arXiv preprint arXiv:1904.09675*, 2019. URL <https://arxiv.org/abs/1904.09675>. ICLR 2020.
- [51] В. Ю. Вашкявичус and О. В. Павлова. Перевод имён собственных (на материале китайских художественных текстов). *Вестник МГПУ. Серия «Филология. Теория языка. Языковое образование»*, (3 (39)), 2020. doi: 10.25688/2076-913X.2020.39.3.09.
- [52] Tianyu Gao et al. Enabling large language models to generate text with citations. *arXiv preprint arXiv:2305.14627*, 2023. URL <https://arxiv.org/abs/2305.14627>. EMNLP 2023.
- [53] Dayeon Ki, Marine Carpuat, Paul McNamee, Daniel Khashabi, Eugene Yang, Dawn Lawrie, and Kevin Duh. Linguistic nepotism: Trading-off quality for language preference in multilingual RAG. *arXiv preprint arXiv:2509.13930*, 2025. URL <https://arxiv.org/abs/2509.13930>.
- [54] Akari Asai, Jungo Kasai, Jonathan H. Clark, Kenton Lee, Eunsol Choi, and Hannaneh Hajishirzi. XOR QA: Cross-lingual open-retrieval question answering. *arXiv preprint arXiv:2010.11856*, 2020. URL <https://arxiv.org/abs/2010.11856>. NAACL 2021.
- [55] Wei Liu et al. XRAG: Cross-lingual retrieval-augmented generation. *arXiv preprint arXiv:2505.10089*, 2025. URL <https://arxiv.org/abs/2505.10089>.
- [56] Nikita Martynov, Anastasia Mordasheva, Dmitriy Gorbetskiy, Danil Astafurov, Ulyana Isaeva, Elina Basyrova, Sergey Skachkov, Victoria Berestova, Nikolay Ivanov, Valeriia Zanina, and Alena Fenogenova. Eye of judgement: Dissecting the evaluation of Russian-speaking LLMs with POLLUX. *arXiv preprint arXiv:2505.24616*, 2025. URL <https://arxiv.org/abs/2505.24616>.
- [57] Fedor Sadkovskii, Regina Nasyrova, and Alexey Sorokin. RusHallu-RAG: Benchmarking hallucination detection for Russian RAG. In *Компьютерная лингвистика и интеллектуальные технологии: по материалам международной конференции «Диалог»*, pages 516–534, 2026. doi: 10.29003/2075-7182-2026-24-516-534.

- [58] Cyril Cleverdon. The Cranfield tests on index language devices. *Aslib Proceedings*, 19(6): 173–194, 1967. doi: 10.1108/eb050097.
- [59] Michael E. Lesk and Gerard Salton. Relevance assessments and retrieval system evaluation. *Information Storage and Retrieval*, 4(4):343–359, 1968. doi: 10.1016/0020-0271(68)90029-6.
- [60] Ellen M. Voorhees. Variations in relevance judgments and the measurement of retrieval effectiveness. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 315–323, 1998. doi: 10.1145/290941.291017.
- [61] Ellen M. Voorhees and Dawn M. Tice. The TREC-8 question answering track evaluation. NIST Special Publication 500-246, National Institute of Standards and Technology, 1999.
- [62] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. doi: 10.1145/582415.582418.
- [63] David Hull. Using statistical testing in the evaluation of retrieval experiments. In *Proceedings of the 16th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 329–338, 1993. doi: 10.1145/160688.160758.
- [64] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. doi: 10.2307/3001968.
- [65] Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1): 1–26, 1979. doi: 10.1214/aos/1176344552.
- [66] Philipp Koehn. Statistical significance tests for machine translation evaluation. In *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing*, pages 388–395, 2004. URL <https://aclanthology.org/W04-3250/>.
- [67] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. URL <https://www.jstor.org/stable/4615733>.
- [68] Norman Cliff. Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3):494–509, 1993. doi: 10.1037/0033-2909.114.3.494.
- [69] Charles Spearman. The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1):72–101, 1904. doi: 10.2307/1412159.
- [70] Rotem Dror, Gili Baumer, Segev Shlomov, and Roi Reichart. The hitchhiker’s guide to testing statistical significance in natural language processing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1383–1392, 2018. doi: 10.18653/v1/P18-1128.
- [71] Evan Miller. Adding error bars to evals: A statistical approach to language model evaluations. *arXiv preprint arXiv:2411.00640*, 2024. URL <https://arxiv.org/abs/2411.00640>.
- [72] Sam Bowyer, Laurence Aitchison, and Desi R. Ivanova. Position: Don’t use the CLT in LLM evals with fewer than a few hundred datapoints. *arXiv preprint arXiv:2503.01747*, 2025. URL <https://arxiv.org/abs/2503.01747>.
- [73] Chen Feng, Minghe Shen, Ananth Balashankar, Carsten Gerner-Beuerle, and Miguel R. D. Rodrigues. Noisy but valid: Robust statistical evaluation of LLMs with imperfect judges. *arXiv preprint arXiv:2601.20913*, 2026. URL <https://arxiv.org/abs/2601.20913>.

А Приложение

А.1 Правила исключения вопросов E_1 – E_5

Правила применяются аннотаторами до разметки инвариантности; вопрос, к которому применимо хотя бы одно правило, в G^+ не включается.

- E_1 **Прогнозы и гипотетика.** Вопросы о будущем и условные конструкции («что произойдёт, если . . . », «как изменится . . . »).
- E_2 **Маркеры текущего момента.** Слова и обороты «сейчас», «на данный момент», «последний», «новейший», «текущая ситуация» и их эквиваленты, привязывающие ответ к моменту запроса.
- E_3 **Величины без даты-якоря.** Цены, курсы валют, биржевые индексы, численность, действующие должностные лица без указания даты, на которую запрашивается значение. Вопрос сохраняется, если дата-якорь добавлена явно («по данным на 12 мая 2023 года»).
- E_4 **Зависимость от момента запроса или оценки.** Ответ требует политической, моральной или иной оценочной позиции либо меняется в зависимости от того, когда задан вопрос.
- E_5 **Ложная предпосылка.** Вопрос предполагает событие или факт, которого не было; такие вопросы могут попасть в $G^\emptyset$ только при явной пометке типа.

В терминах таксономии [14]: допускаются вопросы never-changing; slow-changing — только с датой-якорем; fast-changing и false-premise исключаются.

А.2 Схема записи эталонной выборки

Записи G хранятся в формате JSON Lines; одна строка — одна запись. Значения строковых полей на русском и китайском языках в примере заменены многоточием.

```
{
  "id": "ea-000001",
  "version": "1.0",
  "split": "test",
  "question": {"ru": "...", "zh": "...", "en": "..."},
  "question_type": "factoid",
  "category": "economy",
  "answerable": true,
  "answer": {
    "canonical": "...",
    "aliases": ["...", "..."],
    "type": "entity",
    "lang": "ru"
  },
  "supporting_docs": [
    {
      "webpage_id": "...",
      "urn_uuid": "urn:uuid:...",
      "uri": "https://...",
      "published_at": "2023-05-12",
      "source": "thenewslens.com",
      "evidence_span_ru": "...",
      "evidence_span_zh": "..."
    }
  ],
  "requires_multi_doc": false,
  "time_invariance": {
    "label": "never-changing",
    "anchor_date": "2023-05-12",
    "votes": [1, 1, 1],
    "exclusion_rules_checked": ["E1", "E2", "E3", "E4", "E5"]
  }
}
```

```

    },
    "difficulty": "medium",
    "provenance": {
      "draft_model": "...",
      "draft_prompt_id": "draft-v1",
      "seed_pool_ref": null,
      "annotators": ["a1", "a2", "a3"],
      "adjudicated": false,
      "created_at": "2026-11-01T00:00:00Z"
    }
  }
}

```

Поле `answerable` равно `false` для записей $G^\emptyset$; в них `answer.canonical` принимает значение отказа, а `supporting_docs` пусто. Поле `time_invariance.votes` содержит метки $z_r(q)$ трёх аннотаторов, по которым вычисляется (2).