Система оценки качества ответов больших языковых моделей по новостным текстам стран Восточной Азии

A System for Evaluating the Quality of Large Language Model Answers on East Asian News Texts

Багров Александр Михайлович
Факультет вычислительной математики и кибернетики
МГУ имени М. В. Ломоносова
Москва, Россия
alexbagrov04@gmail.com

Научный руководитель: Воронцов Константин Вячеславович, д. ф.-м. н.
Факультет вычислительной математики и кибернетики
МГУ имени М. В. Ломоносова
Москва, Россия

Аннотация

Системы, где большая языковая модель отвечает на вопросы по статьям новостного архива, внедряются быстрее, чем появляются способы проверить их ответы. Существующие проверочные наборы англоязычны или содержат вопросы с меняющимся во времени ответом, а согласие автоматической оценки с людьми и разметчиков между собой обычно не сообщается. В работе строится система оценки ответов на вопросы о новостях Восточной Азии: вопрос задаётся по-русски, источники написаны по-китайски. Оценивается ответ, то есть текст и процитированные документы. Система оценки включает четыре части. Первая: строгая постановка задачи только для вопросов с неизменным во времени ответом, чтобы эталон не устаревал. Вторая: эталонный набор вопросов с ответами и подтверждающими документами, включая вопросы с правильным ответом «не знаю»; каждый вопрос независимо размечают три человека, их согласие измеряется. Третья: метрики правильности, точности ссылок, отказов и поиска; оценки правильности и ссылок, в том числе от другой языковой модели, допускаются к сравнению, только если согласуются с оценками людей на русскоязычных ответах. Четвёртая: попарная статистическая проверка различий систем на одних и тех же вопросах с поправкой на множественные сравнения. Исследуется промышленная система «Chinese Media Analysis» Института востоковедения РАН (архив из 23,9 млн фрагментов). Её предстоит сравнить с шестью открытыми моделями без поиска и по той же поисковой выдаче, всего 13 систем.

Ключевые слова: большие языковые модели, генерация с дополнением извлечёнными данными (RAG), оценка качества ответов, эталонная выборка, статические вопросы, китайскоязычные СМИ, LLM-судья, согласие аннотаторов.

Выпускная квалификационная работа бакалавра. Факультет вычислительной математики и кибернетики МГУ имени М. В. Ломоносова, 2026.

1 Введение

Новостные тексты стран Восточной Азии — основной источник сведений для востоковедов, аналитиков и журналистов, однако объём потока и языковой барьер делают ручной мониторинг невозможным. Естественным инструментом стали системы генерации с дополнением извлечёнными данными (retrieval-augmented generation, RAG) [1]: поисковый компонент находит фрагменты новостей, а большая языковая модель формирует ответ на естественном языке с цитированием источников. Один из таких инструментов — промышленная система «Chinese Media Analysis» Института востоковедения РАН [2]: она отвечает по-русски на вопросы по корпусу китайскоязычных СМИ КНР, Тайваня, Гонконга и Сингапура объёмом 23,9 млн фрагментов. Цель настоящей работы — построить систему оценки качества *ответов* таких систем. Под ответом понимается пара из текста и множества процитированных документов; под эталонной выборкой — набор вопросов с эталонными ответами и опорными документами; под статическим вопросом — вопрос, ответ на который не меняется со временем; под LLM-судьёй — языковая модель, выставляющая ответу балл по заданной рубрике. Постановка кросс-языковая: вопрос задаётся на русском языке, а источники написаны по-китайски. Вызов состоит в том, что качество промышленной системы подтверждено только транскриптами сеансов, а они показывают дефекты: ложную атрибуцию фактов статье другого года, номера цитат вне списка источников, нерелевантные фрагменты, непереведённые китаизмы. Без измеримых критериев нельзя ответить заказчику ни на вопрос «стала ли система лучше после смены модели», ни на вопрос «оправдан ли поиск по корпусу по сравнению с ответом модели без поиска».

Область оценки RAG-систем за три года прошла путь от безэталонных метрик faithfulness и relevance, вычисляемых LLM-судьёй [3], до систематических обзоров [4]. Бенчмарки над новостями и китайскими текстами [5–7] задали словарь проверяемых способностей: устойчивость к шуму, отказ при отсутствии информации, интеграцию нескольких источников. Сложилась практика мета-оценки самих судей [8, 9] и таксономия вопросов по темпу изменения ответа [10, 11]. Для русского языка появились ресурсы оценки генерации, судей и галлюцинаций в RAG [12–14].

Ни одна из этих линий не закрывает задачу целиком. Во-первых, китайские и российские новостные наборы построены из времязависимых вопросов и намеренно обновляются [7, 15, 16], поэтому расхождение ответа с эталоном нельзя отличить от устаревания самого эталона. Во-вторых, согласие судьи с людьми установлено на английском языке, тогда как на русском оно заметно ниже [12, 17], надёжность судьи не гарантирует его валидности [9, 18], а судья систематически завышает оценки собственному семейству моделей [19]. В-третьих, вопросы, правильный ответ на которые — отказ, и согласие аннотаторов между собой в опубликованных наборах, как правило, не сообщаются [20–22], хотя именно готовность отвечать без опоры на корпус различает системы сильнее, чем точность. Таблица 1 сводит ближайшие альтернативы.

В работе предлагается система оценки ответов RAG-систем над заданным новостным корпусом, дающая долговечную эталонную выборку статических вопросов с подмножеством отказов и семейство метрик, валидированных по русскоязычной человеческой разметке, и отличающаяся от аналогов предикатом инвариантности ответа во времени, раздельной мета-оценкой судьи на надёжность и валидность и парной статистикой с поправкой на множественные сравнения. Ближайшая альтернатива — связка динамического китайского набора вроде ChronoQA с безэталонными метриками RAGAS; в отличие от неё предлагаемая система привязана к зафиксированному снимку корпуса, содержит опорные документы для каждого вопроса и проверяет, что каждая метрика измеряет то же, что человек. Программная система [2] — объект исследования, а не результат работы.

Задачи проекта: (1) сформулировать задачу оценки формально; (2) разработать протокол разметки и построить эталонную выборку; (3) реализовать семейство метрик и отобрать валидированное подсемейство; (4) выполнить прогоны тринадцати систем и статистическое сравнение; (5) опубликовать данные, конфигурации и код. **Вклад работы** состоит в следующем:

- формальная постановка задачи оценки ответов на статические вопросы по новостному корпусу: предикат инвариантности $\mathrm{Inv}(q)$, класс систем $\mathcal{H}_{\mathrm{eval}}$, семейство метрик M, композитный показатель $Q(f)$ и критерий сравнения с проверкой значимости;
- эталонная выборка $G = G^{+} \sqcup G^{\perp}$ статических вопросов с каноническими ответами, алиасами, опорными документами и вопросами, требующими отказа; протокол

Таблица 1: Ближайшие альтернативы и чего им не хватает для оценки ответов промышленной системы над заданным китайскоязычным корпусом при русском языке вопроса

Работа	Сильные стороны	Чего не хватает
ChronoQA, CDQA, DRAGOn [7, 15, 16]	наборы вопросов по китайским и российским новостям с эталонными ответами и опорой на корпус	вопросы времязависимы по замыслу; нет русского языка ответа, отказов и меры согласия аннотаторов
RGB [5]	способности RAG на новостях на китайском и английском, включая отказ при шуме	не привязан к заданной системе и корпусу; нет опорных документов S_i^* по её индексу
RAGAS [3]	безэталонные метрики faithfulness и relevance	согласие с людьми проверено только на английском; нет правильности по эталону
TREC 2024 RAG [23, 24]	воспроизводимая оценка полноты по атомарным фактам и поддержки цитатами	англоязычный веб-корпус; нет вопросов-отказов; правильная цитата не означает опоры на источник [25]
FreshQA, RecencyQA [10, 11]	таксономия темпоральности; стационарность как размечаемое свойство вопроса	оценивают знание свежих фактов, а не качество ответа над корпусом
REPA, POLLUX, RusHalluRAG [12–14]	русскоязычная разметка ошибок, открытые судьи, детекция галлюцинаций	не вопросно-ответные системы над иноязычным новостным корпусом
Настоящая работа	статический эталон с отказами над заданным корпусом; метрики, валидированные на русскоязычных ответах; парная статистика	метрики поиска воспроизводимы только с доступом к индексу; корпус пока китайскоязычный

независимой разметки $R = 3$ аннотаторами с коэффициентом Криппендорфа α и адъюдикацией;

- валидированное подсемейство метрик M' (правильность по эталону m_J^{corr}, EM, F1, BERTScore, цитирование $\mathrm{CP}_{\mathrm{id}}$, $\mathrm{CR}_{\mathrm{id}}$, $\mathrm{CP}_{\mathrm{ent}}$, отказы AR, $1 - \mathrm{FAR}$), отобранное по коэффициенту Спирмена r_S с человеческими оценками;

- первое систематическое сравнение промышленной RAG-системы с шестью открытыми моделями в режимах без поиска и с общим ретривером (13 систем) с парным бутстрепом, критерием Уилкоксона, поправкой Холма и размером эффекта Δ_{C} Клиффа;

- открытые данные и код: выборка, конфигурации, сырые генерации, снимок списка моделей провайдера, скрипты метрик и статистики.

Цель эксперимента — проверить пять гипотез: превосходит ли промышленная система открытые модели без поиска и с общим ретривером, помогает ли поиск каждой модели (память модели конкурентоспособна с поиском лишь на популярных фактах [26]), согласован ли судья с людьми и значимо ли его самопредпочтение. Данные — выборка G из 200–300 вопросов с долей отказов около $0{,}1$ и подвыборка G_h из 100 вопросов с оценками трёх человек. Порядок работы: пилот на 30 вопросах и правка инструкции, полная разметка и заморозка выборки, прогоны при нулевой температуре, валидация метрик, статистика на выборке порядка 200 вопросов, где интервалы по центральной предельной теореме уже ненадёжны [27].

2 Обзор литературы

Обзор отвечает на три вопроса: как измерять ответ системы с поиском, кому верить — человеку или судье-модели, и как сравнивать системы на выборке порядка двухсот вопросов. Работы сгруппированы в пять классов по блокам аннотированного обзора в репозитории (56 позиций за 1904–2026 годы, из них 26 за последние два года; у каждой — вердикт по гипотезам работы).

2.1 Оценка систем с поиском и вопросно-ответных систем

Парадигму тестовой коллекции — фиксированный корпус, запросы и эталонные оценки релевантности — задали Крэнфилдские эксперименты [28], QA-трек TREC ввёл MRR и ручную проверку ответов [29], а nDCG учла позицию документа в выдаче [30]. Однако метрики выдачи связаны с качеством сгенерированного ответа лишь при совпадении целей поиска и генерации [31]. Фреймворк RAGAS [3] дал безэталонные метрики, но валидирован по людям только на английском. Бенчмарки RGB и CRAG [5, 6] покрывают шум, отказ, многодокументность и китайский язык, причём CRAG различает верный ответ, отказ и галлюцинацию и делит вопросы по темпу изменения фактов; но ни один не привязан к заданному корпусу и не даёт опорных документов по его индексу. Обзор [4] систематизирует метрики, не решая вопроса о переносе на другой язык ответа. Трек TREC 2024 RAG подтвердил воспроизводимость оценки по атомарным фактам и оценки поддержки цитатами [23, 24], однако правильная цитата ещё не означает, что модель на неё опиралась [25], а вводящая в заблуждение выдача делает ответ с поиском хуже ответа без него [32]; выигрыш от поиска зависит от популярности факта [26] — отсюда абляция «с поиском/без поиска» по каждой модели.

2.2 Большие языковые модели как судьи

Работы о MT-Bench и G-Eval [8, 33] показали согласие сильного судьи с людьми на уровне межчеловеческого, но и позиционное смещение и смещение к длинному ответу, откуда — поточечная абсолютная шкала вместо парных сравнений. Самопредпочтение судьи [19] распространяется на родственные модели [34] и сохраняется даже при рубрике с объективными критериями [35]; панель судей разных семейств [36] смягчает его, но не отменяет требования выбирать судью вне множества оцениваемых моделей. Крупнейшая мета-оценка судей [9] разделяет надёжность (воспроизводимость) и валидность (согласие с людьми), а в атрибутированном поиске люди, судьи и метрики согласуются слабо [18]. Согласие зависит от языка: на 25 языках оно нестабильно [17], а на русском ниже, чем на английском [12]. При оценке правильности относительно эталона судья коррелирует с людьми до $0{,}85$ против $0{,}22$ у точного совпадения [37], а половина из 54 судей воспроизводит человеческое суждение об ответах RAG-систем [38]. Вывод: судья необходим, но лишь как кандидат, валидируемый на русскоязычных ответах и вне семейства оцениваемых моделей.

2.3 Временная динамика вопросов, построение выборок, отказы и согласие

Ответ на вопрос — функция времени: FreshQA дал таксономию never-, slow- и fast-changing вопросов [10], а набор RecencyQA [11] — размечаемость стационарности ответа. Китайские и российские наборы CDQA, ChronoQA и DRAGOn [7, 15, 16] строятся из динамических событий, то есть решают противоположную задачу. Отказ остаётся нерешённой задачей [20]: системы с поиском отказываются от вопросов, на которые могли ответить, и отвечают там, где корпус пуст [39, 40], а вопросы с заведомо отсутствующим ответом различают системы сильнее, чем точность [21]. Согласие аннотаторов измеряется коэффициентами с поправкой на случайность — от κ Коэна и Флейсса [41, 42] до α Криппендорфа [43], допускающей более двух аннотаторов; обзор [22] даёт ориентиры $0{,}67$ и $0{,}8$, F-мера служит согласием для свободных ответов [44].

2.4 Китайско- и русскоязычные ресурсы и метрики генерации

Метрики точного совпадения и токенного F1 введены в SQuAD [45] и ломаются на перефразировании, а BERTScore [46] смягчает это, но валидирован на коротких текстах. Русская передача китайских имён допускает несколько равноправных вариантов [47], что требует алиасов в эталоне. Метрики цитирования ALCE [48] определяют «поддержку» утверждения источником. Постановку «вопрос на одном языке — свидетельства на другом» формализует XRAG [49], показывая падение качества при смене языка выдачи. Русскоязычные ресурсы REPA, POLLUX и RusHallu-RAG [12–14] покрывают оценку генерации, открытых судей и детекцию галлюцинаций; вопросно-ответных систем над иноязычным новостным корпусом среди них нет, а статья [2] описывает исследуемую систему без количественной оценки.

2.5 Статистика сравнения систем

Парные критерии по запросам корректнее сравнения средних [50]: критерий знаковых рангов Уилкоксона [51] и парный бутстреп по примерам [52] не требуют нормальности, поправка Холма [53] контролирует ошибку при множественных сравнениях, порядковый размер эффекта Клиффа [54] уместен для шкалы 0–5, а коэффициент Спирмена [55] служит критерием валидности метрик. Отказ от нормального приближения при выборках меньше нескольких сотен [27] задаёт рамку для $n \approx 200$; шум несовершенного судьи учитывается калибровкой по человеческой подвыборке [56]. Все эти работы предполагают одну метрику, поэтому композитный показатель требует анализа чувствительности к весам.

Вывод. Существующие работы решают по одному из трёх требований: долговечный эталон над заданным корпусом, метрики, валидированные на русскоязычных ответах независимым судьёй, и корректная статистика при $n \approx 200$. Ни одна не решает их одновременно, и в этом состоит пробел, который закрывает формализация раздела 3.

3 Формализация оценки ответов на статические вопросы по новостному корпусу

3.1 Общее описание

Мы решаем задачу оценки качества ответов вопросно-ответных систем на основе больших языковых моделей над зафиксированным снимком новостного корпуса. Дано: снимок корпуса китайскоязычных СМИ с оригиналами и машинными переводами документов; конечное множество систем-чёрных ящиков, каждая из которых по вопросу на русском языке возвращает текст ответа и множество процитированных документов; разметка людей на подвыборке вопросов. Требуется найти: эталонную выборку статических вопросов с эталонными ответами, опорными документами и вопросами, требующими отказа; подсемейство метрик, согласованных с человеческими оценками; упорядочение систем по композитному показателю с проверкой статистической значимости различий. Качество измеряется коэффициентом Спирмена между метрикой и оценками людей (для метрик) и композитным показателем с парными бутстреп-интервалами (для систем).

3.2 Обозначения

Обозначения вводятся один раз и используются во всех документах репозитория и в коде без изменений (таблица 2). Латинские буквы обозначают объекты и индексы, греческие — коэффициенты и статистики; единственное исключение — ретривер ρ, закреплённый в идентификаторах систем. Каллиграфические буквы обозначают пространства и множества, та же буква курсивом — другой объект: $\mathcal{Q}$ — пространство вопросов, $Q(f)$ — композитный показатель; $\mathcal{H}$ — класс систем, H_1–H_5 — статистические гипотезы. Символ α обозначает только коэффициент согласия Криппендорфа; уровень значимости записывается числом. Отказ обозначается $\perp$, пустое множество — $\varnothing$; индикатор события — $\mathbb{I}[\cdot]$.

3.3 Определения и предположения

Определение 1 (статический вопрос)**.** *Пусть $a^*(q,t) \in \mathcal{A}$ — истинный ответ на вопрос q при состоянии мира в момент t. Вопрос q называется статическим (инвариантным во времени) относительно t_0, если*

$$\mathrm{Inv}(q) \iff \exists\, a^*(q) \in \mathcal{A}^+ :\ \forall t \geq t_0 \quad a^*(q,t) = a^*(q). \tag{1}$$

Определение 2 (ответ системы)**.** *Ответом системы $f \in \mathcal{H}$ на вопрос q называется пара $f(q) = (\hat{a}, \hat{S})$: текст ответа $\hat{a} \in \mathcal{A}$ и множество процитированных документов $\hat{S} \in 2^{\mathcal{I}}$. Отказ $\hat{a} = \perp$ — тоже ответ; у систем без поиска $\hat{S} = \varnothing$. Метрика $m_k(\hat{a}, \hat{S};\, G_i)$ определена на ответах; система входит в неё только через $f(q)$.*

Определение 3 (эталонная выборка)**.** *Эталонной выборкой называется $G = G^+ \sqcup G^\perp$, где $G^+ = \{(q_i, A_i^*, S_i^*, \mu_i)\}_{i=1}^{n_+}$ — статические вопросы с непустым множеством эталонных ответов A_i^* (канонический ответ и алиасы, включая транслитерации), опорными документами*

$|S_i^*| \geq 1$ *и метаданными* μ_i *(тип, категория, источник, дата-якорь, голоса аннотаторов, сложность, разбиение), а* $G^\perp$ *— вопросы, инвариантные по форме, но не подтверждаемые корпусом, для которых правильным ответом является отказ* $\perp$*;* $n_\perp \approx 0{,}1\,n$*.*

Предположение 1 (операционализация инвариантности)**.** *Предикат* (1) *непроверяем непосредственно, поэтому вопрос признаётся статическим, если (а) существует непустое* $S_q^* \subset \mathcal{I}$*, документы которого влекут ответ,* $\{x_\iota\}_{\iota \in S_q^*} \models a^*(q)$*, то есть ответ выводим из снимка* D_{t_0} *и не требует знаний вне него; (б) для вопросов о медленно меняющихся величинах вопрос содержит явную дату-якорь. Оценка по меткам* R *аннотаторов* $z_r(q) \in \{0, 1\}$*:*

$$\widehat{\mathrm{Inv}}(q) = \mathbb{I}\Big[\sum_{r=1}^{R} z_r(q) = R\Big]. \tag{2}$$

Предположение 2 (правила исключения)**.** *До разметки инвариантности к вопросу применяются правила* E_1*–*E_5 *(приложение А.1):* E_1 *— прогнозы и гипотетика;* E_2 *— маркеры «сейчас», «на данный момент», «последний», «текущая ситуация»;* E_3 *— величины без даты-якоря (цены, курсы, индексы, действующие должностные лица);* E_4 *— ответ зависит от момента запроса или политической оценки;* E_5 *— ложная предпосылка. В терминах [10] допускаются вопросы never-changing, вопросы slow-changing — только с датой-якорем; fast-changing и false-premise исключаются.*

Предположение 3 (независимость судьи)**.** *Модель-судья* ℓ_J*, реализующая метрики* m_J^{corr} *и* $m_J^{(c)}$*, не принадлежит множеству* $\mathcal{L} \cup \{\ell_{\mathrm{prod}}\}$ *и не является родственной моделью того же семейства; в противном случае используется ансамбль двух судей из разных семейств. Самопредпочтение судьи проверяется отдельно (гипотеза* H_5*).*

Предположение 4 (воспроизводимость прогонов)**.** *Генерация выполняется при temperature* 0 *и фиксированном seed; поле* `model` *каждого ответа и снимок списка моделей провайдера (*`/v1/models`*) сохраняются; при неизвестной модели прогон прерывается (fail-fast), что исключает тихую подмену модели провайдером.*

3.4 Выборка и гипотезы о порождении данных

Генеральная совокупность — статические вопросы на русском языке, ответ на которые подтверждается снимком D_{t_0}. Порождающий процесс выборки G фиксирован протоколом: стратифицированный отбор документов из снимка (домен $\times$ месяц $\times$ категория, переизбыток $\times 2$) $\to$ черновик кортежа $(q, a, S, \text{evidence}, \text{тип}, \text{дата})$ генератором g_{draft} на модели $\ell_{\mathrm{draft}} \notin \mathcal{L}$ $\to$ независимые метки $z_r(q)$, отвечаемости и типа от $R = 3$ аннотаторов $\to$ фильтр (2) и адъюдикация расхождений четвёртым экспертом. Принимаются допущения: (i) вопросы q_i — независимые реализации из этой совокупности, поэтому ранжирование систем обобщается только на неё; (ii) при temperature 0 и фиксированном seed выход $f(q_i)$ детерминирован, остаточная недетерминированность сервера измеряется повторным прогоном подвыборки; (iii) метки $z_r(q)$ и оценки $h_{i,f}^{(r)}$ условно независимы между аннотаторами при данных q и f (ослепление систем, рандомизация порядка предъявления); (iv) все системы отвечают на одни и те же вопросы, поэтому дизайн парный, а разности δ_i независимы по i; (v) доля $n_\perp \approx 0{,}1\,n$ задана конструктивно, а не оценивается. Существующие 388 вопросов из репозитория объекта исследования — исходный пул черновиков, а не выборка: у них нет эталонных ответов и признака статичности.

3.5 Условия измерений и ограничения на выборку

Снимок D_{t_0} фиксируется датой, числом документов N и хешем списка $\mathcal{I}$; каждый $S_i^* \subset \mathcal{I}$ присутствует в индексе, поэтому покрытие корпуса равно 1 по построению. Выдача ретривера $\rho_{\mathrm{prod}}(q)$ вычисляется один раз, кэшируется и подаётся всем системам $f_\rho^{(\ell)}$ одинаковой; генерация выполняется при temperature 0, фиксированном seed и одном ответе на вопрос с записью фактического поля `model` (предположение 4); судья работает при temperature 0, его воспроизводимость измеряется повторными прогонами подвыборки. Ограничения на выборку: $n \geq 150$ (цель 200–300), $n_\perp \approx 0{,}1\,n$, не менее трёх доменов, двух регионов и охват по датам публикации не менее 12 месяцев; разбиение dev (30 вопросов) для отладки инструкции и промптов и test для итоговой таблицы; пороги $r_{\min}, \alpha \geq 0{,}67$ и первичная метрика фиксируются до прогонов; после заморозки версии `v1.0` ответы и алиасы test-разбиения не изменяются.

3.6 Класс моделей

Класс систем и оцениваемое подмножество:

$$\mathcal{H} = \{f : \mathcal{Q} \to \mathcal{A} \times 2^{\mathcal{I}}\}, \qquad f(q) = (\hat{a}, \hat{S}), \tag{3}$$

$$\mathcal{H}_{\text{eval}} = \{f_{\text{prod}}\} \cup \{f_0^{(\ell)}\}_{\ell \in \mathcal{L}} \cup \{f_\rho^{(\ell)}\}_{\ell \in \mathcal{L}}, \qquad |\mathcal{H}_{\text{eval}}| = 1 + 2|\mathcal{L}| = 13, \tag{4}$$

где три режима заданы формулами

$$f_{\text{prod}}(q) = g_{\text{prod}}\big(q, \rho_{\text{prod}}(q)\big), \qquad f_0^{(\ell)}(q) = \big(g_\ell(q), \varnothing\big), \qquad f_\rho^{(\ell)}(q) = g_\ell\big(q, \rho_{\text{prod}}(q)\big) : \tag{5}$$

промышленная система (генератор поверх ретривера Qdrant + SearchAPI), открытая модель без поиска и та же модель поверх общей выдачи промышленного ретривера (абляция «модель против ретривера»). Ограничения на класс: генераторы, ретривер и эмбеддинги не дообучаются; промпты одинаковы для всех систем одного режима; параметры системы оценки (w_k, $r_{\min}$) фиксированы до эксперимента и по данным не подбираются; судья удовлетворяет предположению 3.

3.7 Критерии качества

Семейство метрик $M = \{m_k\}$, $m_k : \mathcal{A} \times 2^{\mathcal{I}} \times G_i \to [0,1] \cup \{\text{NA}\}$, ориентация «больше — лучше»:

- по эталону (на G^+): $\text{EM} = \max_{a \in A_i^*} \mathbb{I}[\text{norm}(\hat{a}) = \text{norm}(a)]$; токенный F1 после лемматизации, максимум по алиасам; BERTScore-F1 с мультиязычным энкодером; m_J^{corr} — LLM-судья «правильность относительно A_i^*», шкала 0–5, делённая на 5; $m_J^{(c)}$, $c \in \mathcal{C} = \{$faithfulness, answer_relevancy, completeness, citation_accuracy, temporal_correctness, allegory_idiom_quality, hallucination_abstention$\}$ — существующая рубрика как кандидатное подсемейство;
- цитирование: $\text{CP}_{\text{id}} = |\hat{S} \cap S_i^*|/|\hat{S}|$ (NA при $\hat{S} = \varnothing$), $\text{CR}_{\text{id}} = |\hat{S} \cap S_i^*|/|S_i^*|$ (для систем без поиска равна 0), $\text{CP}_{\text{ent}} = \frac{1}{|\hat{S}|} \sum_{\iota \in \hat{S}} \mathbb{I}[x_\iota \models \hat{a}]$ по модели NLI или судье [48];
- отказы: $\text{AR} = \frac{1}{n_\perp} \sum_{G^\perp} \mathbb{I}[\hat{a} = \perp]$ и $1 - \text{FAR}$, где $\text{FAR} = \frac{1}{n_+} \sum_{G^+} \mathbb{I}[\hat{a} = \perp]$;
- поиск (компонент ρ_{prod}): Hit@K, Recall@K, MRR, nDCG@K относительно S_i^*.

Средние по вопросам и композитный показатель:

$$\bar{m}_k(f) = \frac{1}{|I_k(f)|} \sum_{i \in I_k(f)} m_k\big(f(q_i); G_i\big), \qquad I_k(f) = \{i : \ m_k(f(q_i); G_i) \neq \text{NA}\}, \tag{6}$$

$$Q(f) = \sum_{m_k \in M'_Q} w_k \, \bar{m}_k(f), \qquad w_k \geq 0, \ \sum_k w_k = 1. \tag{7}$$

Внутренний критерий — то, что максимизируется в постановке: композитный показатель $Q(f)$ по валидированному подсемейству. Метрика допускается к сравнению систем, только если измеряет то же, что человек:

$$M' = \big\{m_k \in M : \ r_S(m_k, \bar{h}) \geq r_{\min} \text{ на } G_h \times \mathcal{H}_h\big\} \cup M_{\text{det}}, \qquad r_{\min} = 0{,}5, \tag{8}$$

где r_S вычисляется по парам (i, f) с 95 %-м бутстреп-интервалом, потолком служит среднее попарное согласие аннотаторов, а M_{det} — детерминированные метрики без человеческого аналога (AR, $1 - \text{FAR}$, CR_{id}, метрики поиска), включаемые непосредственно. Состав композита $M'_Q \subset M'$ — метрики, определённые на ответах (по эталону, цитирования, отказов); метрики поиска характеризуют компонент ρ_{prod}, одинаковый у всех систем с поиском, и публикуются отдельно. Композит объединяет правильность, проверяемость и отказы, потому что каждая из них порознь тривиально максимизируется: всегда отвечать, никогда не цитировать или всегда отказываться. Веса по умолчанию равные; чувствительность ранжирования к весам публикуется.

Внешние критерии — то, что понятно читателю и заказчику: человеческие оценки $\bar{h}_{i,f}$ по шкалам правильности и обоснованности с потолком «человек–человек»; интерпретируемые

метрики с интервалами по отдельности — m_J^{corr} или F1 (правильность), $\mathrm{CP}_{\mathrm{ent}}$ (проверяемость), AR и $1 - \mathrm{FAR}$ (безопасность отказов); практические показатели — число вызовов и время прогона, приводимые описательно. Внутренний критерий даёт упорядочение систем, внешние — покомпонентную таблицу, по которой видно, за счёт чего система выиграла.

3.8 Процедура валидации

Обучения в постановке нет, поэтому вместо кросс-валидации используются: (а) разбиение dev/test, где dev служит только для отладки инструкции и промптов; (б) отбор M' по (8) на $G_h \times \mathcal{H}_h$ с кластерным бутстрепом по вопросам ($B = 10^4$) и контрольной проверкой по половинам G_h — метрика, отобранная на одной половине, должна сохранять $r_S \geq r_{\min}$ на другой; (в) парный бутстреп по вопросам для $\bar{\delta}$ и $Q(f)$; (г) надёжность судьи — повторные прогоны подвыборки при temperature 0 с отчётом о доле совпадений баллов; (д) согласие аннотаторов α_G при разметке G и α_h по шкалам валидации; (е) устойчивость ранжирования к весам w_k (исключение метрик по одной, случайные веса, τ Кендалла между ранжированиями); (ж) воспроизводимость: git sha кода, снимок `/v1/models`, сырые генерации.

3.9 Ограничения на решения

Выборка: $n \geq 150$, $n_\perp \approx 0{,}1\,n$, не менее трёх доменов и двух регионов, охват не менее 12 месяцев, $S_i^* \subset \mathcal{I}$ и $|S_i^*| \geq 1$. Метрики: в M' входят только метрики с $r_S \geq r_{\min}$ либо из M_{det}; первичная метрика — m_J^{corr}, если она проходит (8), иначе F1. Судья: $\ell_J \notin \mathcal{L} \cup \{\ell_{\mathrm{prod}}\}$. Данные: публикуются идентификаторы, URL, даты и короткие фрагменты-свидетельства, но не полные тексты документов. Время: защита в июне 2027 года.

3.10 Формальная запись задачи

Найти эталонную выборку G, удовлетворяющую ограничениям выше, валидированное подсемейство метрик (8) и лучшую систему

$$f^\star = \arg\max_{f \in \mathcal{H}_{\mathrm{eval}}} Q(f) = \arg\min_{f \in \mathcal{H}_{\mathrm{eval}}} \sum_{m_k \in M'_Q} w_k \big(1 - \bar{m}_k(f)\big), \tag{9}$$

где $1 - \bar{m}_k(f)$ — доля ошибок по k-й метрике, так что минимизируемый функционал есть взвешенная доля ошибок системы. Для пары систем (f, f') на общих вопросах $i \in I_k(f) \cap I_k(f')$ вычисляются разности $\delta_i = m_k(f(q_i)) - m_k(f'(q_i))$; для $\bar{\delta}$ строится перцентильный 95 %-й интервал парным бутстрепом по вопросам ($B = 10^4$); применяется двусторонний критерий Уилкоксона знаковых рангов (нулевые разности делятся между знаками; для бинарных метрик — точный критерий Мак-Немара) с поправкой Холма на уровне значимости $0{,}05$ в четырёх семьях: первичная метрика и $Q(f) \times 12$ сравнений $f' \neq f_{\mathrm{prod}}$ (гипотезы H_1, H_2) и 6 пар $(f_\rho^{(\ell)}, f_0^{(\ell)})$ (гипотеза H_3); размер эффекта — Δ_{C} Клиффа. Различие $Q(f^\star) - Q(f')$ признаётся установленным, если $p_{\mathrm{Holm}} < 0{,}05$ и интервал для $\bar{\delta}$ не содержит нуля; иначе публикуется множество статистически неразличимых лидеров. Проверяемые гипотезы:

- H_1 (основная): $Q(f_{\mathrm{prod}}) > Q(f_0^{(\ell)})$ для всех $\ell \in \mathcal{L}$;
- H_2 (сильная): $Q(f_{\mathrm{prod}}) > Q(f_\rho^{(\ell)})$ для всех $\ell \in \mathcal{L}$; при опровержении вклад ретривера и модели разделяется явно;
- H_3: $Q(f_\rho^{(\ell)}) > Q(f_0^{(\ell)})$ для всех $\ell \in \mathcal{L}$ — поиск по корпусу повышает качество ответов каждой модели;
- H_4: $r_S(m_J^{\mathrm{corr}}, \bar{h}) \geq 0{,}5$ и $\alpha_h \geq 0{,}67$ — метрика правильности по эталону валидна, а человеческая разметка согласована;
- H_5: самопредпочтение судьи статистически незначимо.

Отрицательный результат по H_1–H_3 — допустимый исход работы, поскольку её предметом является система оценки, а не превосходство конкретной системы.

4 Метод

Система оценки строится за девять этапов; каждый этап описан так, чтобы его мог воспроизвести другой исследователь по опубликованным конфигурациям.

1. **Отбор документов.** Стратифицированная выборка из пересечения хранилища веб-страниц и индекса Qdrant по стратам «домен $\times$ месяц $\times$ категория» с переизбытком $\times 2$; фиксируются t_0, N и хеш списка $\mathcal{I}$.
2. **Черновики вопросов.** Генератор g_{draft} на модели $\ell_{\mathrm{draft}} \notin \mathcal{L}$ порождает по документу кортеж $(q, a, S, \text{evidence}, \text{тип}, \text{дата})$. Существующие 388 вопросов [2] после перекладки ключей `warc_id` $\rightarrow$ `webpage_id` служат исходным пулом (seed pool), а не эталоном: у них нет эталонных ответов и признака статичности.
3. **Независимая разметка.** $R = 3$ аннотатора (не менее одного читающего по-китайски) независимо размечают инвариантность по правилам E_1–E_5, отвечаемость, тип вопроса и правят ответ.
4. **Согласие.** По меткам инвариантности, отвечаемости и типа вычисляется коэффициент Криппендорфа α_G ($\alpha_G \geq 0{,}67$ допустимо, $\alpha_G \geq 0{,}8$ надёжно); по ответам — попарный токенный F1 с порогом $0{,}8$.
5. **Сборка G.** Вопрос включается при единогласии (2), при расхождении — после адъюдикации четвёртым экспертом. Пилот на 30 вопросах $\rightarrow$ правка инструкции $\rightarrow$ полный прогон $\rightarrow$ заморозка версии `v1.0` (sha256, журнал изменений).
6. **Метрики M.** Реализуются метрики по эталону, цитирования, отказов и поиска из раздела 3; существующая рубрика подключается как кандидатное подсемейство $\{m_J^{(c)}\}_{c \in \mathcal{C}}$.
7. **Валидация M'.** На G_h ($n_h = 100$) собираются оценки $h_{i,f}^{(r)}$ для систем $\mathcal{H}_h$; по (8) отбираются метрики с $r_S \geq r_{\min}$; вычисляется α_h; отдельно проверяется самопредпочтение судьи.
8. **Прогоны.** Для всех $f \in \mathcal{H}_{\mathrm{eval}}$ при temperature 0 и фиксированном seed сохраняются сырые генерации, цитирования, поле `model`, git sha и снимок `/v1/models` (предположение 4).
9. **Статистика.** Вычисляются $\bar{m}_k(f)$, $Q(f)$ (7), парные разности δ_i с бутстреп-интервалами, критерий Уилкоксона с поправкой Холма и Δ_{C} Клиффа; результаты сводятся в таблицу вида таблицы 4.

5 Эксперименты

Цель вычислительного эксперимента. Базовый эксперимент проверяет исходную посылку постановки: эталонные ответы существующих наборов вопросов устаревают, и скорость устаревания зависит от типа вопроса. Если эталон времязависимого вопроса за год-два перестаёт совпадать с действительностью, то расхождение ответа системы с таким эталоном нельзя считать ошибкой системы, и ограничение выборки статическими вопросами (определение 1) необходимо. Поэтому измеряется доля вопросов, эталонный ответ которых изменился за заданный срок, отдельно для каждого типа вопроса. Основной эксперимент (раздел 5.2) проверяет гипотезы H_1–H_5 на собственной эталонной выборке G.

5.1 Базовый эксперимент: устаревание эталонов существующих наборов

Данные. Набор FreshQA [10] содержит 600 англоязычных вопросов с разметкой типа факта: never-changing, slow-changing и fast-changing. Авторы набора регулярно обновляют эталонные ответы и публикуют каждую версию отдельной таблицей. Из 87 версий за период с 15 октября 2023 по 21 апреля 2026 года для выгрузки доступны 75. Базовая версия v_0 — от 15 октября 2023 года; в первом прогоне с ней сравниваются девять более поздних версий, по одной на квартал.

Измеряемая величина. Вопросы двух версий сопоставляются по нормализованному тексту, потому что идентификаторы между версиями не сохраняются; сопоставлено 535 из 600

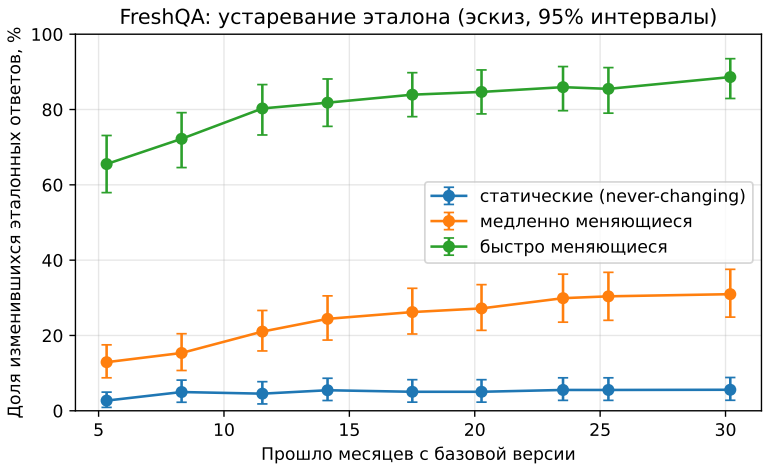


Рис. 1: Эскиз графика ошибок: доля изменившихся эталонных ответов FreshQA в зависимости от времени, прошедшего с базовой версии; отрезки — 95 %-е бутстреп-интервалы

вопросов. Для вопроса q и версии v индикатор $s(q;v) = \mathbb{I}[A^*_v(q) \neq A^*_{v_0}(q)]$ равен единице, если после приведения регистра и пробелов изменилось множество эталонных ответов; строгий вариант учитывает только канонический ответ. Доля устаревших эталонов для типа вопроса — среднее $s(q;v)$ по вопросам этого типа с 95 %-м перцентильным бутстреп-интервалом по вопросам ($B = 10^4$).

Первые результаты приведены в таблице 3 и на рис. 1. Через пять месяцев изменились две трети эталонов быстро меняющихся вопросов, через 30 месяцев — 89 %; у медленно меняющихся за тот же срок изменился почти каждый третий эталон. У вопросов, которые авторы набора считают неизменными, доля изменений не превышает 6 % и со временем почти не растёт. Это переформулировки, правки алиасов и исправления ошибок эталона, а как минимум два из двенадцати таких вопросов размечены неверно: «сколько таксофонов осталось в Нью-Йорке» и «сколько дней осталось до коронации Карла III». Вывод черновика: эталон времязависимых вопросов за год-два становится непригоден для оценки, статические вопросы его сохраняют, а сама разметка статичности требует проверки несколькими аннотаторами. Ограничение: сравнение строковое, поэтому переформулировка ответа засчитывается как изменение, и оценка для неизменных вопросов является верхней границей.

5.2 План основного эксперимента

Для проверки гипотез запланирована эмпирическая часть, параметры которой фиксируются до начала прогонов.

Оцениваемые системы. $\mathcal{L} = \{$DeepSeek-R1-Distill-Qwen-32B [57], Qwen3.6-27B и Qwen3.8-27B [58], GigaChat-20B-A3B [59], GLM-4.1V-9B-Thinking [60], Qwen-AgentWorld-35B-A3B$\}$ — шесть открытых моделей провайдера ИВ РАН (исключены специализированные Hy-MT2, Laguna-XS и Qwen3-Coder). В двух режимах ($f_0^{(\ell)}$ и $f_\rho^{(\ell)}$) вместе с f_{prod} это даёт $|\mathcal{H}_{\text{eval}}| = 13$ систем.

Размеры. Эталонная выборка $n = 200$–300 (не менее 150), $n_\perp \approx 0{,}1\,n$, $R = 3$ аннотатора, подвыборка человеческой валидации $n_h = 100$, разбиение dev/test $= 30/(n-30)$.

Бюджет вычислений. Разметка: 250×5 мин ≈ 21 ч на каждого из трёх аннотаторов. Генерации: $13 \times 250 = 3250$ ответов, с dev-прогонами и повторами для проверки воспроизводимости — около 4750 вызовов (около 40 ч последовательно). Судья: около 25 ч. При сокращённом варианте (защита зимой): $n = 150$, 8 систем, $n_h = 60$.

Гипотезы. H_1–H_5 в формулировке раздела 3: H_1 — $Q(f_{\text{prod}}) > Q(f_0^{(\ell)})$ и H_2 — $Q(f_{\text{prod}}) > Q(f_\rho^{(\ell)})$ для всех $\ell \in \mathcal{L}$; H_3 — $Q(f_\rho^{(\ell)}) > Q(f_0^{(\ell)})$ для всех $\ell \in \mathcal{L}$; H_4 — $r_S(m_J^{\text{corr}}, \bar{h}) \geq 0{,}5$ и $\alpha_h \geq 0{,}67$; H_5 — самопредпочтение судьи незначимо.

План работ. Сентябрь–октябрь 2026 — постановка, инструкция разметки, пилот на 30 вопросах, обзор литературы; ноябрь–декабрь — разметка 250 вопросов и заморозка `v1.0`; январь 2027 — прогоны; февраль — валидация метрик и статистика; март–апрель — текст и слайды; защита — июнь 2027.

6 Обсуждение

Самопредпочтение судьи. Фактический генератор промышленной системы ℓ_{prod} — DeepSeek-R1-Distill-Qwen-32B, входящая и в $\mathcal{L}$. Если судья ℓ_J окажется той же или родственной моделью, оценки m_J^{corr} будут смещены в пользу её ответов [19, 34]. Меры: предположение 3, гипотеза H_5, панель судей разных семейств [36] и опора на детерминированные метрики EM, F1, CP_{id} как контроль.

Подмена модели провайдером. Локальный провайдер (llama-swap) может тихо заменить неизвестную модель на модель по умолчанию, что уже наблюдалось для конфигурации по умолчанию. Мера: fail-fast, запись поля `model` каждого ответа и снимка списка моделей (предположение 4).

Утечка знаний в предобучение. События 2022–2023 годов могли попасть в обучающие данные открытых моделей, и высокий результат $f_0^{(\ell)}$ может отражать память модели, а не рассуждение по корпусу; известно, что на популярных сущностях параметрическая память конкурентоспособна с поиском [26]. Мера: страта «известность события» в метаданных μ_i и описательная разбивка результатов по ней; вопросы $G^\perp$ дополнительно проверяют склонность к уверенному ответу без опоры [21].

Транслитерация имён и терминов. Русская передача китайских имён и названий неоднозначна [47], что ломает EM и токенный F1. Мера: алиасы в A_i^* и мягкие метрики (BERTScore, m_J^{corr}); согласие судьи с человеком на таких вопросах проверяется отдельно.

Область применимости. В названии работы указаны страны Восточной Азии, тогда как корпус исследуемой системы на текущем этапе китайскоязычный. Методика не зависит от языка корпуса, а расширение выборки на японские и корейские источники требует лишь повторения этапов 1–5 раздела 4 с аннотаторами, владеющими соответствующими языками. Метрики поиска воспроизводимы только при доступе к индексу ИВ РАН; все прочие метрики воспроизводимы по опубликованным данным.

7 Заключение

В работе поставлена задача оценки качества ответов больших языковых моделей на статические вопросы по новостному корпусу стран Восточной Азии: введён предикат инвариантности $\text{Inv}(q)$, определены эталонная выборка $G = G^+ \sqcup G^\perp$, класс систем $\mathcal{H}_{\text{eval}}$, семейство метрик M и композитный показатель $Q(f)$ с процедурой статистического сравнения, завершающейся утверждением (9). Предложена девятиэтапная методика построения системы оценки, включающая независимую разметку тремя аннотаторами, измерение согласия и валидацию метрик по человеческим оценкам. Сформулированы гипотезы H_1–H_5 и план экспериментов над промышленной системой [2] и шестью открытыми моделями в двух режимах. Результатом работы станут опубликованная эталонная выборка, валидированное подсемейство метрик M' и главная таблица результатов с интервалами и поправкой на множественные сравнения.

Список литературы

[1] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020. URL `https://arxiv.org/abs/2005.11401`.

[2] А. М. Багров, Н. В. Иванченко, А. В. Костыркин, Р. Ф. Кудакаев, А. А. Маркин, and А. Ч. Мокрецкий. К вопросу о цифровых инструментах анализа СМИ стран Северо-Восточной Азии. *Проблемы Дальнего Востока*, (1):147–156, 2026. doi: 10.7868/S2712909826010109.

[3] Shahul Es et al. Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023. URL https://arxiv.org/abs/2309.15217. EACL 2024, System Demonstrations.

[4] Aoran Gan et al. Retrieval augmented generation evaluation in the era of large language models: A comprehensive survey. *arXiv preprint arXiv:2504.14891*, 2025. URL https://arxiv.org/abs/2504.14891.

[5] Jiawei Chen et al. Benchmarking large language models in retrieval-augmented generation. *arXiv preprint arXiv:2309.01431*, 2023. URL https://arxiv.org/abs/2309.01431. AAAI 2024.

[6] Xiao Yang et al. CRAG – comprehensive RAG benchmark. *arXiv preprint arXiv:2406.04744*, 2024. URL https://arxiv.org/abs/2406.04744. NeurIPS 2024, Datasets and Benchmarks Track.

[7] Ziyang Chen et al. A question answering dataset for temporal-sensitive retrieval-augmented generation. *arXiv preprint arXiv:2508.12282*, 2025. URL https://arxiv.org/abs/2508.12282.

[8] Lianmin Zheng et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *arXiv preprint arXiv:2306.05685*, 2023. URL https://arxiv.org/abs/2306.05685. NeurIPS 2023, Datasets and Benchmarks Track.

[9] Justin D. Norman, Michael U. Rivera, and D. Alex Hughes. Reliability without validity: A systematic, Large-Scale evaluation of LLM-as-a-Judge models across agreement, consistency, and bias. *arXiv preprint arXiv:2606.19544*, 2026. URL https://arxiv.org/abs/2606.19544.

[10] Tu Vu et al. FreshLLMs: Refreshing large language models with search engine augmentation. *arXiv preprint arXiv:2310.03214*, 2023. URL https://arxiv.org/abs/2310.03214.

[11] Bhawna Piryani, Zehra Mert, and Adam Jatowt. How often do answers change? estimating recency requirements in question answering. *arXiv preprint arXiv:2603.16544*, 2026. URL https://arxiv.org/abs/2603.16544.

[12] Alexander Pugachev, Alena Fenogenova, Vladislav Mikhailov, and Ekaterina Artemova. REPA: Russian error types annotation for evaluating text generation and judgment capabilities. *arXiv preprint arXiv:2503.13102*, 2025. URL https://arxiv.org/abs/2503.13102.

[13] Nikita Martynov, Anastasia Mordasheva, Dmitriy Gorbetskiy, Danil Astafurov, Ulyana Isaeva, Elina Basyrova, Sergey Skachkov, Victoria Berestova, Nikolay Ivanov, Valeriia Zanina, and Alena Fenogenova. Eye of judgement: Dissecting the evaluation of Russian-speaking LLMs with POLLUX. *arXiv preprint arXiv:2505.24616*, 2025. URL https://arxiv.org/abs/2505.24616.

[14] Fedor Sadkovskii, Regina Nasyrova, and Alexey Sorokin. RusHallu-RAG: Benchmarking hallucination detection for Russian RAG. In *Компьютерная лингвистика и интеллектуальные технологии: по материалам международной конференции «Диалог»*, pages 516–534, 2026. doi: 10.29003/2075-7182-2026-24-516-534.

[15] Zhikun Xu et al. Let LLMs take on the latest challenges! A Chinese dynamic question answering benchmark. *arXiv preprint arXiv:2402.19248*, 2024. URL https://arxiv.org/abs/2402.19248. COLING 2025.

[16] Fedor Chernogorskii, Sergei Averkiev, Liliya Kudraleeva, Zaven Martirosian, Maria Tikhonova, Valentin Malykh, and Alena Fenogenova. DRAGOn: Designing RAG on periodically updated corpus. *arXiv preprint arXiv:2507.05713*, 2025. URL https://arxiv.org/abs/2507.05713.

[17] Xiyan Fu and Wei Liu. How reliable is multilingual LLM-as-a-Judge? *arXiv preprint arXiv:2505.12201*, 2025. URL https://arxiv.org/abs/2505.12201.

[18] Lukas Gienapp, Jenny Lang, Martin Potthast, and Harrisen Scells. Humans, LLMs, and measures do not align in attributed information retrieval. In *Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 3738–3742, 2026. doi: 10.1145/3805712.3809867.

[19] Arjun Panickssery et al. LLM evaluators recognize and favor their own generations. *arXiv preprint arXiv:2404.13076*, 2024. URL https://arxiv.org/abs/2404.13076.

[20] Polina Kirichenko, Mark Ibrahim, Kamalika Chaudhuri, and Samuel J. Bell. AbstentionBench: Reasoning LLMs fail on unanswerable questions. *arXiv preprint arXiv:2506.09038*, 2025. URL https://arxiv.org/abs/2506.09038.

[21] Alden Do Rosario, Hussein Younes, and Felipe Pires. Why RAGs hallucinate: Penalty-Aware evaluation of Retrieval-Augmented generation systems with Knowledge-Gap canaries. *arXiv preprint arXiv:2608.26385*, 2026. URL https://arxiv.org/abs/2608.26385.

[22] Ron Artstein and Massimo Poesio. Survey article: Inter-coder agreement for computational linguistics. *Computational Linguistics*, 34(4):555–596, 2008. doi: 10.1162/coli.07-034-R2. URL https://aclanthology.org/J08-4004/.

[23] Ronak Pradeep, Nandan Thakur, Shivani Upadhyay, Daniel Campos, Nick Craswell, and Jimmy Lin. The great nugget recall: Automating fact extraction and RAG evaluation with large language models. *arXiv preprint arXiv:2504.15068*, 2025. URL https://arxiv.org/abs/2504.15068.

[24] Nandan Thakur, Ronak Pradeep, Shivani Upadhyay, Daniel Campos, Nick Craswell, Ian Soboroff, Hoa Trang Dang, and Jimmy Lin. Assessing support for the TREC 2024 RAG track: A large-scale comparative study of LLM and human evaluations. In *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2759–2763, 2025. doi: 10.1145/3726302.3730165.

[25] Jonas Wallat, Maria Heuss, Maarten de Rijke, and Avishek Anand. Correctness is not faithfulness in retrieval augmented generation attributions. In *Proceedings of the 2025 International ACM SIGIR Conference on Innovative Concepts and Theories in Information Retrieval (ICTIR)*, pages 22–32, 2025. doi: 10.1145/3731120.3744592.

[26] Alex Mallen, Akari Asai, Victor Zhong, Rajarshi Das, Daniel Khashabi, and Hannaneh Hajishirzi. When not to trust language models: Investigating effectiveness of parametric and Non-Parametric memories. *arXiv preprint arXiv:2212.10511*, 2022. URL https://arxiv.org/abs/2212.10511.

[27] Sam Bowyer, Laurence Aitchison, and Desi R. Ivanova. Position: Don't use the CLT in LLM evals with fewer than a few hundred datapoints. *arXiv preprint arXiv:2503.01747*, 2025. URL https://arxiv.org/abs/2503.01747.

[28] Cyril Cleverdon. The Cranfield tests on index language devices. *Aslib Proceedings*, 19(6): 173–194, 1967. doi: 10.1108/eb050097.

[29] Ellen M. Voorhees and Dawn M. Tice. The TREC-8 question answering track evaluation. NIST Special Publication 500-246, National Institute of Standards and Technology, 1999.

[30] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. doi: 10.1145/582415.582418.

[31] Saron Samuel, Alexander Martin, Eugene Yang, Andrew Yates, Dawn Lawrie, Ian Soboroff, Laura Dietz, and Benjamin Van Durme. Beyond relevance: On the relationship between retrieval and RAG information coverage. *arXiv preprint arXiv:2603.08819*, 2026. URL https://arxiv.org/abs/2603.08819.

[32] Linda Zeng, Rithwik Gupta, Divij Motwani, Yi Zhang, and Diji Yang. Worse than zero-shot? a Fact-Checking dataset for evaluating the robustness of RAG against misleading retrievals. *arXiv preprint arXiv:2502.16101*, 2025. URL https://arxiv.org/abs/2502.16101.

[33] Yang Liu et al. G-Eval: NLG evaluation using GPT-4 with better human alignment. *arXiv preprint arXiv:2303.16634*, 2023. URL https://arxiv.org/abs/2303.16634.

[34] Dawei Li, Renliang Sun, Yue Huang, Ming Zhong, Bohan Jiang, Jiawei Han, Xiangliang Zhang, Wei Wang, and Huan Liu. Preference leakage: A contamination problem in LLM-as-a-judge. *arXiv preprint arXiv:2502.01534*, 2025. URL https://arxiv.org/abs/2502.01534.

[35] José Pombal, Ricardo Rei, and André F. T. Martins. Self-Preference bias in Rubric-Based evaluation of large language models. *arXiv preprint arXiv:2604.06996*, 2026. URL https://arxiv.org/abs/2604.06996.

[36] Pat Verga, Sebastian Hofstätter, Sophia Althammer, Yixuan Su, Aleksandra Piktus, Arkady Arkhangorodsky, Minjie Xu, Naomi White, and Patrick Lewis. Replacing judges with juries: Evaluating LLM generations with a panel of diverse models. *arXiv preprint arXiv:2404.18796*, 2024. URL https://arxiv.org/abs/2404.18796.

[37] Xanh Ho, Jiahao Huang, Florian Boudin, and Akiko Aizawa. Reassessing extractive QA datasets at scale: LLM-as-a-Judge and In-Depth analyses. *arXiv preprint arXiv:2504.11972*, 2025. URL https://arxiv.org/abs/2504.11972.

[38] Steve Han, Gilberto Titericz Junior, Tom Balough, and Wenfei Zhou. Judge's verdict: A comprehensive analysis of LLM judge capability through human agreement. *arXiv preprint arXiv:2510.09738*, 2025. URL https://arxiv.org/abs/2510.09738.

[39] Youchao Zhou, Heyan Huang, Yicheng Liu, Rui Dai, Xinglin Wang, Xingchen Zhang, Shumin Shi, and Yang Deng. Do retrieval augmented language models know when they don't know? *arXiv preprint arXiv:2509.01476*, 2025. URL https://arxiv.org/abs/2509.01476.

[40] Gabrielle Kaili-May Liu, Bryan Li, Arman Cohan, William Gantt Walden, and Eugene Yang. Investigating Retrieval-Augmented generation systems on unanswerable, uncheatable, realistic, multi-hop queries. *arXiv preprint arXiv:2510.11956*, 2025. URL https://arxiv.org/abs/2510.11956.

[41] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960. doi: 10.1177/001316446002000104.

[42] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971. doi: 10.1037/h0031619.

[43] Klaus Krippendorff. Estimating the reliability, systematic error and random error of interval data. *Educational and Psychological Measurement*, 30(1):61–70, 1970. doi: 10.1177/001316447003000105.

[44] George Hripcsak and Adam S. Rothschild. Agreement, the F-measure, and reliability in information retrieval. *Journal of the American Medical Informatics Association*, 12(3):296–298, 2005. doi: 10.1197/jamia.M1733.

[45] Pranav Rajpurkar et al. SQuAD: 100,000+ questions for machine comprehension of text. *arXiv preprint arXiv:1606.05250*, 2016. URL https://arxiv.org/abs/1606.05250. EMNLP 2016.

[46] Tianyi Zhang et al. BERTScore: Evaluating text generation with BERT. *arXiv preprint arXiv:1904.09675*, 2019. URL https://arxiv.org/abs/1904.09675. ICLR 2020.

[47] В. Ю. Вашкявичус and О. В. Павлова. Перевод имён собственных (на материале китайских художественных текстов). *Вестник МГПУ. Серия «Филология. Теория языка. Языковое образование»*, (3 (39)), 2020. doi: 10.25688/2076-913X.2020.39.3.09.

[48] Tianyu Gao et al. Enabling large language models to generate text with citations. *arXiv preprint arXiv:2305.14627*, 2023. URL https://arxiv.org/abs/2305.14627. EMNLP 2023.

[49] Wei Liu et al. XRAG: Cross-lingual retrieval-augmented generation. *arXiv preprint arXiv:2505.10089*, 2025. URL https://arxiv.org/abs/2505.10089.

[50] David Hull. Using statistical testing in the evaluation of retrieval experiments. In *Proceedings of the 16th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 329–338, 1993. doi: 10.1145/160688.160758.

[51] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. doi: 10.2307/3001968.

[52] Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1): 1–26, 1979. doi: 10.1214/aos/1176344552.

[53] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. URL https://www.jstor.org/stable/4615733.

[54] Norman Cliff. Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3):494–509, 1993. doi: 10.1037/0033-2909.114.3.494.

[55] Charles Spearman. The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1):72–101, 1904. doi: 10.2307/1412159.

[56] Chen Feng, Minghe Shen, Ananth Balashankar, Carsten Gerner-Beuerle, and Miguel R. D. Rodrigues. Noisy but valid: Robust statistical evaluation of LLMs with imperfect judges. *arXiv preprint arXiv:2601.20913*, 2026. URL https://arxiv.org/abs/2601.20913.

[57] DeepSeek-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025. URL https://arxiv.org/abs/2501.12948.

[58] Qwen Team. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025. URL https://arxiv.org/abs/2505.09388.

[59] GigaChat team. GigaChat family: Efficient Russian language modeling through mixture of experts architecture. *arXiv preprint arXiv:2506.09440*, 2025. URL https://arxiv.org/abs/2506.09440. ACL 2025, System Demonstrations.

[60] GLM Team. ChatGLM: A family of large language models from GLM-130B to GLM-4 all tools. *arXiv preprint arXiv:2406.12793*, 2024. URL https://arxiv.org/abs/2406.12793.

A Приложение

A.1 Правила исключения вопросов E_1–E_5

Правила применяются аннотаторами до разметки инвариантности; вопрос, к которому применимо хотя бы одно правило, в G^+ не включается.

- E_1 **Прогнозы и гипотетика.** Вопросы о будущем и условные конструкции («что произойдёт, если . . . », «как изменится . . . »).
- E_2 **Маркеры текущего момента.** Слова и обороты «сейчас», «на данный момент», «последний», «новейший», «текущая ситуация» и их эквиваленты, привязывающие ответ к моменту запроса.
- E_3 **Величины без даты-якоря.** Цены, курсы валют, биржевые индексы, численность, действующие должностные лица без указания даты, на которую запрашивается значение. Вопрос сохраняется, если дата-якорь добавлена явно («по данным на 12 мая 2023 года»).
- E_4 **Зависимость от момента запроса или оценки.** Ответ требует политической, моральной или иной оценочной позиции либо меняется в зависимости от того, когда задан вопрос.
- E_5 **Ложная предпосылка.** Вопрос предполагает событие или факт, которого не было; такие вопросы в $G^\perp$ не включаются: у вопросов $G^\perp$ предпосылка верна, но ответа в корпусе нет.

В терминах таксономии [10]: допускаются вопросы never-changing; slow-changing — только с датой-якорем; fast-changing и false-premise исключаются.

A.2 Схема записи эталонной выборки

Записи G хранятся в формате JSON Lines; одна строка — одна запись; схема — `data/golden_set/schema.json`. Значения строковых полей на русском и китайском языках в примере заменены многоточием.

```
{
  "id": "gs-0001",
  "version": "v1.0",
  "split": "test",
  "question": {"ru": "...", "zh": "...", "en": "..."},
  "question_type": "when",
  "category": "economy",
  "answerable": true,
  "answer": {
    "canonical": "...",
    "aliases": ["...", "..."],
    "type": "date",
    "lang": "ru"
  },
  "supporting_docs": [
    {
      "webpage_id": 1234567,
      "urn_uuid": "123e4567-e89b-12d3-a456-426614174000",
      "uri": "https://...",
      "published_at": "2023-05-12",
      "source": "thenewslens.com",
      "evidence_span_ru": "...",
      "evidence_span_zh": "..."
    }
  ],
  "requires_multi_doc": false,
  "time_invariance": {
    "label": "never_changing",
    "anchor_date": "2023-05-12",
```

```
    "votes": [1, 1, 1],
    "exclusion_rules_checked": ["E1", "E2", "E3", "E4", "E5"]
  },
  "difficulty": "medium",
  "provenance": {
    "draft_model": "...",
    "draft_prompt_id": "draft-v1",
    "seed_pool_ref": null,
    "annotators": ["A1", "A2", "A3"],
    "adjudicated": false,
    "created_at": "2026-11-01T00:00:00Z"
  }
}
```


Поле `answerable` равно `false` для записей $G^{\perp}$; в них `answer` равно `null`, а `supporting_docs` пусто. Поле `time_invariance.votes` содержит метки $z_r(q)$ трёх аннотаторов, по которым вычисляется (2).

Таблица 2: Основные обозначения

Символ	Смысл
Данные	
t_0	момент фиксации снимка корпуса
$D_{t_0} = \{d_j\}_{j=1}^{N}$, $D \equiv D_{t_0}$	снимок корпуса из N документов; $d_j = (\iota_j, u_j, \tau_j, s_j, x_j^{zh}, x_j^{ru})$ — стабильный идентификатор, URL, дата публикации $\tau_j \le t_0$, источник, текст оригинала, машинный перевод; x_ι — текст документа ι
$\mathcal{I}$	множество идентификаторов ι_j; фрагмент любого ретривера отображается в ι_j
$\mathcal{Q}$, q	пространство вопросов на русском языке и вопрос
$\mathcal{A} = \mathcal{A}^+ \sqcup \{\perp\}$	пространство ответов; $\mathcal{A}^+$ — содержательные ответы, $\perp$ — отказ «Я не знаю.»
$2^{\mathcal{I}}$	пространство цитирований (множеств идентификаторов)
Эталонная выборка	
$a^*(q,t)$, $a^*(q)$, $\mathrm{Inv}(q)$	истинный ответ при состоянии мира в момент t; инвариантный ответ; предикат инвариантности
R, $z_r(q)$, $\widehat{\mathrm{Inv}}(q)$	число аннотаторов ($R = 3$); метка инвариантности r-го аннотатора; оценка предиката по меткам
E_1–E_5	правила исключения вопросов (приложение А.1)
$G = G^+ \sqcup G^\perp$	эталонная выборка: отвечаемые вопросы и вопросы, требующие отказа; $\lvert G^+\rvert = n_+$, $\lvert G^\perp\rvert = n_\perp$, $n = n_+ + n_\perp$
$G_i = (q_i, A_i^*, S_i^*, \mu_i)$	запись G^+: вопрос, множество эталонных ответов (канонический и алиасы), опорные документы $S_i^* \subset \mathcal{I}$, $\lvert S_i^*\rvert \ge 1$, метаданные
$G_h \subset G^+$, n_h	подвыборка человеческой валидации и её объём ($n_h = 100$)
Системы	
$\mathcal{H}$, $\mathcal{H}_{\mathrm{eval}}$, $\mathcal{H}_h$	класс систем $\{f : \mathcal{Q} \to \mathcal{A} \times 2^{\mathcal{I}}\}$; оцениваемое подмножество (13 систем); системы, оцениваемые людьми
$f(q) = (\hat{a}, \hat{S})$	ответ системы f: текст ответа и множество процитированных документов
$\mathcal{L}$, ℓ	множество открытых моделей провайдера ($\lvert\mathcal{L}\rvert = 6$) и модель из него
g_ℓ, g_{prod}, g_{draft}	генератор на модели ℓ; генератор промышленной системы; генератор черновиков вопросов
ℓ_{prod}, ℓ_J, ℓ_{draft}	фактическая модель промышленного генератора; модель-судья; модель черновиков; $\ell_J \notin \mathcal{L} \cup \{\ell_{\mathrm{prod}}\}$, $\ell_{\mathrm{draft}} \notin \mathcal{L}$
ρ_{prod}, K	ретривер промышленной системы и глубина выдачи ($K \in \{1,3,5,10\}$)
f_{prod}, $f_0^{(\ell)}$, $f_\rho^{(\ell)}$	промышленная система; модель ℓ без поиска; модель ℓ поверх выдачи ρ_{prod}
Метрики	
$M = \{m_k\}$, M_{det}, M', M'_Q	семейство метрик; детерминированные метрики без человеческого аналога; валидированное подсемейство; состав композита
NA, norm	значение «неприменимо»; нормализация строки перед сравнением
m_J^{corr}, $m_J^{(c)}$, $\mathcal{C}$	судья: правильность относительно A_i^*; судья по критерию c рубрики; семь критериев рубрики
$\mathrm{CP_{id}}$, $\mathrm{CR_{id}}$, $\mathrm{CP_{ent}}$, AR, FAR	точность и полнота цитирования по идентификаторам, точность по следованию; доля верных и ложных отказов
$h_{i,f}^{(r)}$, $\bar{h}_{i,f}$	оценка r-го аннотатора ответа $f(q_i)$ и её среднее по r
$I_k(f)$, $\bar{m}_k(f)$, w_k, $Q(f)$, $f^\star$	вопросы, на которых $m_k \ne \mathrm{NA}$; среднее метрики; веса; композитный показатель; лучшая система
Статистика	
α, α_G, α_h	коэффициент Криппендорфа; согласие аннотаторов при разметке G; согласие людей по шкалам 0–5 на G_h
r_S, $r_{\min}$	коэффициент ранговой корреляции Спирмена; порог включения метрики ($r_{\min} = 0{,}5$)
δ_i, $\bar{\delta}$, B	поточечная и средняя разность метрики двух систем; число бутстреп-повторений ($B = 10^4$)
Δ_{C}, p_{Holm}	размер эффекта Клиффа; p-значение после поправки Холма

Таблица 3: Доля изменившихся эталонных ответов FreshQA через 30 месяцев после базовой версии (21 апреля 2026 года против 15 октября 2023 года); в скобках — 95 %-й бутстреп-интервал

Тип вопроса	n	Множество ответов, %	Канонический ответ, %
never-changing	215	5,6 [2,8; 8,8]	3,3 [0,9; 5,6]
slow-changing	197	31,0 [24,9; 37,6]	26,4 [20,3; 32,5]
fast-changing	123	88,6 [82,9; 93,5]	87,0 [80,5; 92,7]

Таблица 4: Заготовка главной таблицы результатов. В ячейках — $\bar{m}_k(f)$ с 95 %-м бутстреп-интервалом; звёздочкой отмечаются различия с f_{prod}, значимые после поправки Холма ($p_{\mathrm{Holm}} < 0{,}05$). Значения будут заполнены после прогонов.

Система	Режим	m_J^{corr}	F1	$\mathrm{CP}_{\mathrm{id}}$	AR	$1 - \mathrm{FAR}$	$Q(f)$ (ранг)
f_{prod}	Qdrant + SearchAPI	…	…	…	…	…	…
$f_0^{(\ell_1)}$	без поиска	…	…	NA	…	…	…
$f_0^{(\ell_2)}$	без поиска	…	…	NA	…	…	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
$f_\rho^{(\ell_1)}$	ρ_{prod}	…	…	…	…	…	…
$f_\rho^{(\ell_2)}$	ρ_{prod}	…	…	…	…	…	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮