

Система оценки качества ответов больших языковых моделей по
новостным текстам стран Восточной Азии
A System for Evaluating the Quality of Large Language Model Answers on East Asian
News Texts

Багров Александр Михайлович

Научный руководитель: Воронцов Константин Вячеславович, д. ф.-м. н.

Факультет вычислительной математики и кибернетики МГУ имени
М. В. Ломоносова

Проект по курсу: оформление по шаблону «Моя первая научная статья»

Система оценки качества ответов больших языковых моделей

Промышленная RAG-система «Chinese Media Analysis» (ИБ РАН) отвечает по-русски на вопросы по 23,9 млн фрагментов китайскоязычных СМИ, но качество её ответов до сих пор оценивалось только качественно.

Цель

Построить систему оценки качества *ответов* $\hat{a} = f(q)$ на вопросы о новостном корпусе: эталонную выборку, валидированные метрики и статистический протокол сравнения.

Проблема


Готовые средства оценки RAG опираются на невалидированного LLM-судью; существующие наборы вопросов устаревают, так как ответы зависят от времени; сравнение промышленной системы с открытыми моделями не проводилось.

Решение

- 1) Ограничиться статическими вопросами: $\text{Inv}(q)$ — ответ не меняется при $t \geq t_0$.
- 2) Построить $G = G^+ \sqcup G^\emptyset$ с разметкой $R = 3$ и согласием Криппендорфа α .
- 3) Отобрать метрики $M' \subset M$ по согласию с людьми и сравнить 13 систем по $Q(f)$. 2/7

Работа на одном слайде

От снимка корпуса к таблице результатов: шесть этапов, каждый воспроизводим по опубликованным конфигурациям.



1) Обозначения: D , $\mathcal{Q}$, $\mathcal{A} = \mathcal{A}^+ \sqcup \{\emptyset\}$, $\mathcal{I}$, $\text{Inv}(q)$, G , $\mathcal{H}$, M , $Q(f)$.

2) Объекты: ответ $\hat{a} = f(q)$ — объект измерения; система f входит только через $f(q)$.

1) Данные: $n = 200\text{--}300$ статических вопросов, $n_\emptyset \approx 0,1 n$.

2) Системы: f_{prod} и 6 открытых моделей в двух режимах ($|\mathcal{H}_{\text{eval}}| = 13$).

Следствие: получаем долговечный эталон, метрики с известным согласием с человеком и таблицу сравнения с интервалами и поправкой на множественные сравнения.

Постановка задачи

Дано. Снимок корпуса $D = \{d_j\}_{j=1}^N$, $d_j = (\iota_j, u_j, \tau_j, s_j, x_j^{zh}, x_j^{ru})$, $\tau_j \leq t_0$; пространства $\mathcal{Q}$, $\mathcal{A} = \mathcal{A}^+ \sqcup \{\emptyset\}$, $2^{\mathcal{I}}$;

$$\text{Inv}(q) \iff \exists a^*(q) \in \mathcal{A}^+ : \forall t \geq t_0 \quad a^*(q, t) = a^*(q), \quad \widehat{\text{Inv}}(q) = \mathbb{I}\left[\sum_{r=1}^R z_r(q) = R\right].$$

Эталонная выборка $G = G^+ \sqcup G^\emptyset$, $G^+ = \{(q_i, A_i^*, S_i^*, \mu_i)\}_{i=1}^{n+}$, $\widehat{\text{Inv}}(q_i) = 1$. Класс гипотез $\mathcal{H} = \{f : \mathcal{Q} \rightarrow \mathcal{A} \times 2^{\mathcal{I}}\}$, $\mathcal{H}_{\text{eval}} = \{f_{\text{prod}}\} \cup \{f_0^{(m)}\}_{m \in \mathcal{L}} \cup \{f_\rho^{(m)}\}_{m \in \mathcal{L}}$. Метрики $M = \{m_k\}$, $m_k : \mathcal{A} \times 2^{\mathcal{I}} \times G_i \rightarrow [0, 1] \cup \{\text{NA}\}$; оценки людей $\bar{h}_{i,f}$ на $G_h \subset G^+$.

Найти. Выборку G ; валидированное подсемейство метрик и лучшую систему:

$$M' = \{m_k \in M : \rho_S(m_k, \bar{h}) \geq \rho_{\min}\}, \quad \rho_{\min} = 0,5; \quad Q(f) = \sum_k w_k \bar{m}_k(f), \quad f^* = \arg \max_{f \in \mathcal{H}_{\text{eval}}} Q(f).$$

Критерий. Первичная метрика m_J^{corr} (иначе F1); парный бутстреп по вопросам ($B = 10^4$), критерий Уилкоксона, поправка Холма, уровень значимости 0,05.

Основная гипотеза H_1 : $Q(f_{\text{prod}}) > Q(f_0^{(m)})$ для всех $m \in \mathcal{L}$.

Решение: методика построения системы оценки

- 1) **Отбор и черновики.** Стратифицированный отбор документов (домен $\times$ месяц $\times$ категория, переизбыток $\times 2$); черновики $(q, a, S, \text{evidence})$ моделью $g_{\text{draft}} \notin \mathcal{L}$; 388 старых вопросов — исходный пул.
- 2) **Разметка.** $R = 3$ независимых аннотатора (не менее одного читающего по-китайски); правила исключения $E_1 - E_5$; классы FreshQA: never-changing и slow-changing с датой-якорем.
- 3) **Согласие и сборка G .** Криппендорф $\alpha \geq 0,67$; попарный F1 ответов $\geq 0,8$; включение при единогласии, иначе адьюдикация; пилот 30 $\rightarrow$ полный прогон $\rightarrow$ заморозка v1.0.
- 4) **Метрики M .** По эталону: EM, F1, BERTScore, m_J^{corr} (новое измерение); цитирование: CP_{id} , CR_{id} , CP_{ent} ; отказы: AR, $1 - \text{FAR}$; поиск: $\text{Hit}@k$, $\text{Recall}@k$, MRR, $\text{nDCG}@k$. Существующий семимерный судья — кандидатное подсемейство.
- 5) **Валидация M' .** Оценки людей на G_h ($n_h = 100$); отбор по $\rho_S \geq 0,5$ с бутстреп-интервалом; проверка самопредпочтения судьи (H_5).
- 6) **Прогоны и статистика.** 13 систем при temperature 0; $Q(f)$, парный бутстреп, Уилкоксон, Холм, δ Клиффа; разбивка по стратам.

План экспериментов

Системы ($|\mathcal{H}_{\text{eval}}| = 13$): f_{prod} (Qdrant + SearchAPI + генератор) и $\mathcal{L}$ — шесть открытых моделей провайдера ИВ РАН в режимах без поиска $f_0^{(m)}$ и с общим ретривером $f_{\rho}^{(m)}$.

Размеры: $n = 200\text{--}300$ вопросов ($n \geq 150$), $n_{\varnothing} \approx 0,1 n$, $R = 3$, $n_h = 100$.

Бюджет: разметка ≈ 21 ч на аннотатора; ≈ 4750 генераций (≈ 40 ч); судья ≈ 25 ч.

Гипотезы: $H_1\text{--}H_3$ — сравнение по $Q(f)$; $H_4 - \rho_S(m_J^{\text{corr}}, \bar{h}) \geq 0,5$, $\alpha \geq 0,67$; H_5 — самопредпочтение судьи незначимо.

Система	Режим	m_J^{corr}	F1	CP _{id}	AR	$Q(\cdot)$
f_{prod}	Qdrant + SearchAPI	...	...	...	...	..
$f_0^{(m_1)}$	без поиска	...	...	NA	...	..
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$f_0^{(m_6)}$	без поиска	...	...	NA	...	..
$f_{\rho}^{(m_1)}$	ρ_{prod}	...	...	...	...	..
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$f_{\rho}^{(m_6)}$	ρ_{prod}	...	...	...	...	..

В ячейках — $\bar{m}_k(f)$ с 95 %-м бутстреп-интервалом; звёздочка — значимое отличие от f_{prod} после поправки Холма. Значения появятся после прогонов (январь–февраль 2027).

Заключение

- 1) Будет формализована задача оценки качества ответов на статические вопросы по новостному корпусу: предикат $\text{Inv}(q)$, класс гипотез $\mathcal{H}_{\text{eval}}$, семейство метрик M , показатель $Q(f)$ и критерий сравнения.
- 2) Будет построена и опубликована эталонная выборка $G = G^+ \sqcup G^\emptyset$ ($n = 200\text{--}300$) с разметкой $R = 3$ аннотаторами, мерой согласия α и стабильными идентификаторами документов.
- 3) Будет получено валидированное подсемейство метрик M' , включающее метрику правильности по эталону m_J^{corr} и метрики цитирования и отказов, с оценкой согласия с человеком ρ_S .
- 4) Будет проведено первое систематическое сравнение промышленной системы с открытыми моделями (13 систем) с бутстреп-интервалами и поправкой Холма; проверены гипотезы $H_1\text{--}H_5$.