• Выпускная квалификационная работа •

Система оценки качества ответов больших языковых моделей по новостным текстам стран Восточной Азии

Багров Александр Михайлович
alexbagrov04@gmail.com
Научный руководитель: д. ф.-м. н. К. В. Воронцов

Код, данные и текст работы доступны в репозитории
github.com/Priestprog/east-asia-news-llm-eval

ВМК МГУ • 2026

Содержание

1. **Задача и мотивация**
   - Объект исследования и проблема
   - Цель и идея решения
2. **Постановка задачи и методика**
   - Постановка задачи
   - Методика построения
3. **Эксперименты**
   - Базовый эксперимент: аудит FreshQA
   - План основного эксперимента

Объект исследования и проблема

Промышленная RAG-система «Chinese Media Analysis» (ИВ РАН) отвечает по-русски на вопросы по 23,9 млн фрагментов китайскоязычных СМИ, но качество её ответов до сих пор оценивалось только качественно.

Проблемы:

- готовые средства оценки RAG опираются на невалидированного *LLM-судью*;
- существующие наборы вопросов *устаревают*, так как ответы зависят от времени;
- сравнение промышленной системы с открытыми моделями не проводилось.

Цель и идея решения

Цель: построить систему оценки качества *ответов* $f(q) = (\hat{a}, \hat{S})$ на вопросы о новостном корпусе: эталонную выборку, валидированные метрики и статистический протокол сравнения.

Решение:

1. Ограничиться *статическими* вопросами: $\mathrm{Inv}(q)$ — ответ не меняется при $t \geq t_0$.
2. Построить *эталонную выборку* $G = G^+ \sqcup G^\perp$ с разметкой $R = 3$ аннотаторами и согласием α_G Криппендорфа.
3. Отобрать метрики $M' \subset M$ по согласию с людьми и сравнить 13 систем по $Q(f)$.

Постановка задачи: данные и эталонная выборка

Дано:

- снимок корпуса $D_{t_0} = \{d_j\}_{j=1}^{N}$, $d_j = (\iota_j, u_j, \tau_j, s_j, x_j^{zh}, x_j^{ru})$, $\tau_j \le t_0$;
- пространства $\mathcal{Q}$, $\mathcal{A} = \mathcal{A}^+ \sqcup \{\perp\}$ ($\perp$ — отказ), $2^{\mathcal{I}}$;
- *статичность* вопроса и её оценка по R аннотаторам:

$$\mathrm{Inv}(q) \iff \exists\, a^*(q) \in \mathcal{A}^+ :\ \forall t \ge t_0 \quad a^*(q,t) = a^*(q),$$
$$\widehat{\mathrm{Inv}}(q) = \mathbb{I}\left[\sum\nolimits_{r=1}^{R} z_r(q) = R\right];$$

- *эталонная выборка* $G = G^+ \sqcup G^\perp$, $G^+ = \{(q_i, A_i^*, S_i^*, \mu_i)\}_{i=1}^{n_+}$, $\widehat{\mathrm{Inv}}(q_i) = 1$.

Постановка задачи: системы и метрики

Дано (продолжение):

- класс систем $\mathcal{H} = \{f : \mathcal{Q} \to \mathcal{A} \times 2^{\mathcal{I}}\}$, $f(q) = (\hat{a}, \hat{S})$;
- оцениваемые системы

$$\mathcal{H}_{\text{eval}} = \{f_{\text{prod}}\} \cup \{f_0^{(\ell)}\}_{\ell \in \mathcal{L}} \cup \{f_\rho^{(\ell)}\}_{\ell \in \mathcal{L}},$$

  где $f_{\text{prod}}(q) = g_{\text{prod}}(q, \rho_{\text{prod}}(q))$, $f_0^{(\ell)}(q) = (g_\ell(q), \varnothing)$, $f_\rho^{(\ell)}(q) = g_\ell(q, \rho_{\text{prod}}(q))$;
- метрики $M = \{m_k\}$, $m_k : \mathcal{A} \times 2^{\mathcal{I}} \times G_i \to [0, 1] \cup \{\text{NA}\}$;
- оценки людей $\bar{h}_{i,f}$ на $G_h \subset G^+$.

Постановка задачи: найти и критерий

Найти: выборку G; валидированное подсемейство метрик и лучшую систему:

$$M' = \{m_k \in M : \; r_S(m_k, \bar{h}) \geq r_{\min}\} \cup M_{\text{det}}, \quad r_{\min} = 0{,}5;$$

$$Q(f) = \sum_{m_k \in M'_Q} w_k \, \bar{m}_k(f);$$

$$f^\star = \arg\max_{f \in \mathcal{H}_{\text{eval}}} Q(f) = \arg\min_{f \in \mathcal{H}_{\text{eval}}} \sum_{m_k \in M'_Q} w_k \big(1 - \bar{m}_k(f)\big)$$

(взвешенная доля ошибок).

Критерий: первичная метрика m_J^{corr} (иначе F1); парный бутстреп по вопросам ($B = 10^4$), двусторонний критерий Уилкоксона, поправка Холма в четырёх семьях, уровень значимости 0,05, размер эффекта Δ_C Клиффа; различие установлено при $p_{\text{Holm}} < 0{,}05$ и $\bar{\delta} > 0$.

Основная гипотеза H_1: $Q(f_{\text{prod}}) > Q(f_0^{(\ell)})$ для всех $\ell \in \mathcal{L}$.

Методика: построение эталонной выборки

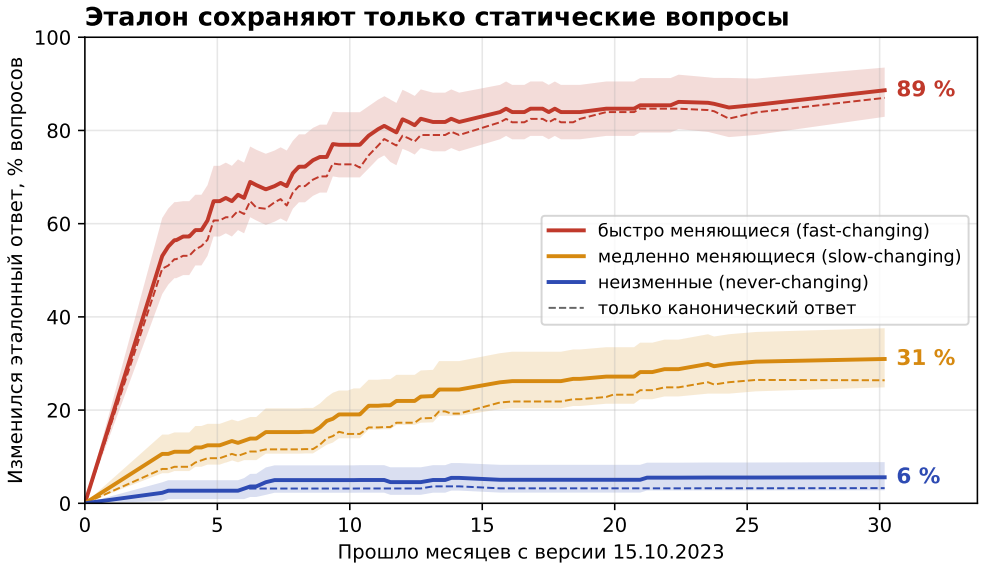
1. **Отбор и черновики.** Стратифицированный отбор документов (домен $\times$ месяц $\times$ категория, переизбыток $\times 2$); черновики $(q, a, S, \text{evidence})$ генератором g_{draft} на модели $\ell_{\text{draft}} \notin \mathcal{L}$; 388 старых вопросов — исходный пул.
2. **Разметка.** $R = 3$ независимых аннотатора (не менее одного читающего по-китайски); правила исключения E_1–E_5; классы FreshQA: never-changing и slow-changing с датой-якорем.
3. **Согласие и сборка** G**.** $\alpha_G \geq 0{,}67$ Криппендорфа; попарный F1 ответов $\geq 0{,}8$; включение при единогласии, иначе адъюдикация; пилот 30 $\rightarrow$ полный прогон $\rightarrow$ заморозка `v1.0`.

Методика: метрики и сравнение систем

4. **Метрики** M**.** По эталону: EM, F1, BERTScore, m_J^{corr} (новый критерий); цитирование: CP_{id}, CR_{id}, CP_{ent}; отказы: AR, $1 - \text{FAR}$; поиск: Hit@K, Recall@K, MRR, nDCG@K. Существующий судья по семи критериям — кандидатное подсемейство.
5. **Валидация** M'**.** Оценки людей на G_h ($n_h = 100$); отбор по $r_S \geq r_{\min} = 0{,}5$ с бутстреп-интервалом; согласие людей α_h; проверка самопредпочтения судьи (H_5).
6. **Прогоны и статистика.** 13 систем при temperature 0; $Q(f)$, парный бутстреп, Уилкоксон, Холм, Δ_C Клиффа; разбивка по стратам.

Базовый эксперимент: устаревание эталонов FreshQA

Данные: FreshQA, 600 вопросов трёх типов; версия от 15.10.2023 против 74 более поздних версий до 21.04.2026.



FreshQA, поздних версий: 74; полосы — 95%-е бутстреп-интервалы по вопросам.

Через 30 месяцев изменились эталоны:

- быстро меняющихся: **89 %**
- медленно меняющихся: **31 %**
- неизменных: **не более 6 %**

Вывод: эталон сохраняют только статические вопросы, но разметку статичности нужно проверять: среди изменившихся «неизменных» вопросов есть ошибочно размеченные.

План основного эксперимента

- **Системы** ($|\mathcal{H}_{\text{eval}}| = 13$): f_{prod} (Qdrant + SearchAPI + генератор) и $\mathcal{L}$ — шесть открытых моделей провайдера ИВ РАН в режимах без поиска $f_0^{(\ell)}$ и с общим ретривером $f_\rho^{(\ell)}$.
- **Размеры:** $n = 200$–300 вопросов ($n \geq 150$), $n_\perp \approx 0{,}1\, n$, $R = 3$, $n_h = 100$.
- **Бюджет:** разметка ≈ 21 ч на аннотатора; ≈ 4750 генераций (≈ 40 ч); судья ≈ 25 ч.
- **Гипотезы:** H_1–H_3 — сравнение по $Q(f)$; H_4 — $r_S(m_J^{\text{corr}}, \bar{h}) \geq 0{,}5$, $\alpha_h \geq 0{,}67$; H_5 — самопредпочтение судьи незначимо.

План основного эксперимента: таблица результатов

Система	Режим	m_J^{corr}	F1	CP_{id}	AR	$Q(f)$
f_{prod}	Qdrant + SearchAPI	…	…	…	…	…
$f_0^{(\ell_1)}$	без поиска	…	…	NA	…	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮
$f_0^{(\ell_6)}$	без поиска	…	…	NA	…	…
$f_\rho^{(\ell_1)}$	ρ_{prod}	…	…	…	…	…
⋮	⋮	⋮	⋮	⋮	⋮	⋮
$f_\rho^{(\ell_6)}$	ρ_{prod}	…	…	…	…	…

В ячейках — $\bar{m}_k(f)$ с 95 %-м бутстреп-интервалом; звёздочка — значимое отличие от f_{prod} после поправки Холма. Значения появятся после прогонов (январь–февраль 2027).

Заключение

1. Будет формализована задача оценки качества ответов на статические вопросы по новостному корпусу: предикат $\mathrm{Inv}(q)$, класс систем $\mathcal{H}_{\mathrm{eval}}$, семейство метрик M, показатель $Q(f)$ и критерий сравнения.
2. Будет построена и опубликована эталонная выборка $G = G^{+} \sqcup G^{\perp}$ ($n = 200$–300) с разметкой $R = 3$ аннотаторами, мерой согласия α_G и стабильными идентификаторами документов.
3. Будет получено валидированное подсемейство метрик M', включающее метрику правильности по эталону m_J^{corr} и метрики цитирования и отказов, с оценкой согласия с человеком r_S.
4. Будет проведено первое систематическое сравнение промышленной системы с открытыми моделями (13 систем) с бутстреп-интервалами и поправкой Холма; проверены гипотезы H_1–H_5.