# Система оценки качества ответов БЯМ СМИ ВА

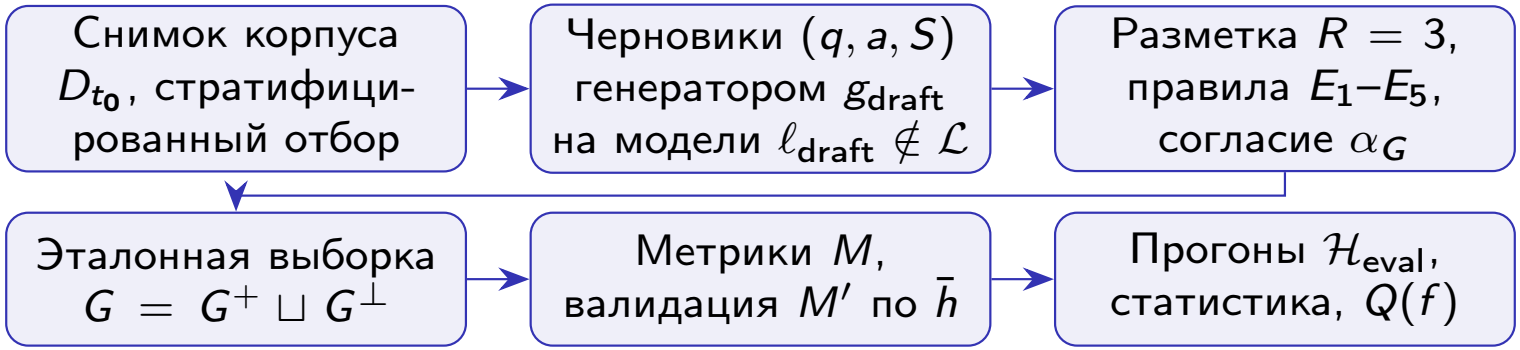



Рис. 1. Схема сравнения промышленной системы с открытыми моделями на созданном статическом эталоне и отобранной системе метрик, согласованной с оценками людей.

**Дано:** корпус китайскоязычных СМИ и 13 систем ответа на вопросы: промышленная RAG-система и 6 открытых БЯМ в двух режимах.

**Найти:** эталон из статических вопросов, метрики, согласованные с людьми, и лучшую систему $f^\star = \arg\max_f Q(f)$.

**Критерий:** согласие метрики с людьми $r_S \geq 0{,}5$; различие систем по парному бутстрепу с поправкой Холма, $p < 0{,}05$.

**Результат:** эталоны существующих наборов устаревают: в FreshQA за 30 месяцев изменились 89 % ответов на быстро меняющиеся вопросы и не более 6 % на неизменные. Поэтому эталон строим только из статических вопросов.